

Sumário

1	A amostra de 1,27% do Censo de 1960: o desenho amostral, reconstruído passo a passo	2
1.1	Parte I — O que é a amostra	3
1.2	1. O Censo de 1960 e as suas duas amostras	3
1.3	2. O vocabulário da época	3
1.3.1	2.1 Boletim, família e domicílio são três coisas diferentes	4
1.4	3. O que os documentos da época dizem sobre o sorteio	5
1.4.1	3.1 O Volume II de 1965: a única descrição do desenho	5
1.4.2	3.2 O que o Volume II não diz	6
1.4.3	3.3 Os outros documentos, e o que cada um acrescenta	7
1.5	4. O que sobreviveu no arquivo	8
1.6	Parte II — A engenharia reversa do sorteio	10
1.7	5. Passo 1: o que a amostra de 1,27% diz sozinha	10
1.7.1	5.1 Os números das pastas são todos pares	10
1.7.2	5.2 A grade de 40 nas cidades grandes	10
1.7.3	5.3 O peso realizado bate com o nominal	13
1.7.4	5.4 O que ficou em aberto depois do passo 1	13
1.8	6. Passo 2: o cadastro de sorteio, reconstruído a partir da amostra de 25%	13
1.8.1	6.1 A ideia	13
1.8.2	6.2 O cadastro	13
1.8.3	6.3 Como o cadastro está ordenado	14
1.9	7. Passo 3: em que estrato o sorteio foi feito?	16
1.9.1	7.1 O teste	16
1.9.2	7.2 As candidatas	17
1.9.3	7.3 Unidade da federação × situação, de perto	20
1.10	8. Passo 4: como o IBGE separava a “cidade de 100 000 e mais habitantes”?	21
1.11	9. O desenho, reconstruído	22
1.12	Parte III — Pesos, colunas de desenho e erros amostrais	23
1.13	10. Os pesos	23
1.13.1	10.1 O peso de desenho	23
1.13.2	10.2 Por que calibrar, e a quê	23
1.13.3	10.3 <code>censobr_weight</code> : calibrado aos resultados definitivos	24
1.13.4	10.4 <code>censobr_weight_1965</code> : calibrado aos resultados preliminares	28
1.13.5	10.5 Como se calibra	29
1.13.6	10.6 O resultado	30
1.13.7	10.7 O que cada peso reproduz, e o que não	30

1.13.8	10.8 O que o peso não faz	30
1.14	11. As colunas de desenho nas tabelas	31
1.15	12. Como calcular o erro-padrão, e o que ele diz	32
1.15.1	12.1 Por que não tratar as 897 mil linhas como 897 mil sorteios	32
1.15.2	12.2 O estimador	32
1.15.3	12.3 O efeito de desenho	33
1.15.4	12.4 O que os números dizem	33
1.16	13. As alternativas de cálculo, uma a uma	35
1.16.1	13.1 O ponto de partida: o que o estimador adotado supõe	36
1.16.2	13.2 A correção de população finita: adotada, e por quê	37
1.16.3	13.3 A estratificação: por que unidade da federação $\times$ situação, e o que a alternativa mais grossa daria	38
1.16.4	13.4 Usar a ordem do cadastro: o estimador de diferenças sucessivas (opção)	39
1.16.5	13.5 A variância depois da calibração: quando ela vale e quando não	41
1.16.6	13.6 Pesos replicados: jackknife (não será feito)	42
1.16.7	13.7 Pesos replicados: bootstrap de Rao e Wu (não será feito)	43
1.16.8	13.8 Domínios pequenos e o que não fazer	43
1.16.9	13.9 O que muda com a amostra de 25%	43
1.16.10	13.10 O que está adotado, o que é opção, o que foi descartado e o que é tarefa	44
1.16.11	13.11 O que deste desenho chega à tabela publicada	44
1.17	14. Como usar em R	45
1.17.1	14.1 Na tabela publicada	45
1.17.2	14.2 Nas tabelas deste estágio	46
1.17.3	14.3 Quatro cuidados, nas duas	46
1.18	15. Limitações e cuidados	47
1.19	16. Glossário	47
1.20	17. Fontes	47

1 A amostra de 1,27% do Censo de 1960: o desenho amostral, reconstruído passo a passo

Este texto acompanha `R/microdata_1960_amostra_127.R` e o documento de preparação (`references/microdata_1960_amostra_127.pdf`). Ele foi escrito para um leitor que domina estatística e análise de dados, tem noções de amostragem (sabe o que é um estrato, um conglomerado, um peso), mas nunca ouviu falar desta amostra, não conhece o vocabulário do IBGE de 1960 e não tem nenhum contexto sobre como as decisões abaixo foram tomadas. Por isso o texto não pressupõe nada: cada afirmação vem acompanhada do documento que a sustenta, do dado que a demonstra ou da declaração explícita de que é uma escolha nossa.

A promessa é que, ao fim, o leitor saiba (1) como a amostra foi sorteada em 1960–1964, (2) o que sobreviveu no arquivo, (3) como o desenho foi reconstruído por engenharia reversa, com os dados e as figuras de cada passo, (4) o que

cada coluna de desenho das tabelas significa, (5) como calcular um erro-padrão correto e (6) por que cada alternativa de cálculo foi adotada, deixada como opção ou descartada.

Tudo o que está aqui é reproduzível. Os números vêm da execução do pipeline (`targets::tar_make()` dos alvos de 1960) em 2026-09-15, com o peso final `censobr_weight` salvo indicação em contrário; as figuras e as tabelas da investigação vêm de `references/figuras/desenho_amostr_1960.R`, que refaz a engenharia reversa do começo ao fim; a conferência contra o pacote `survey` está em `references/conferencia_desenho_amostr_1960.R`.

Organização. A Parte I (seções 1 a 4) diz o que a amostra é e o que os documentos da época dizem sobre ela. A Parte II (seções 5 a 9) é a engenharia reversa: o que o próprio arquivo revela, o cadastro de sorteio reconstruído a partir da amostra de 25%, e os testes que identificam os estratos. A Parte III (seções 10 a 15) trata dos pesos, das colunas de desenho, do cálculo do erro-padrão e das alternativas. Ao fim há um glossário e a lista de fontes.

1.1 Parte I — O que é a amostra

1.2 1. O Censo de 1960 e as suas duas amostras

O Censo Demográfico de 1960 teve data de referência em 1º de setembro de 1960: em cada domicílio foram recenseadas as pessoas que ali passaram a noite de 31 de agosto para 1º de setembro, mais os moradores temporariamente ausentes. O recenseador percorria o seu **setor censitário** — a área de trabalho de um recenseador, com algumas centenas de domicílios; o país foi dividido em 57.914 setores — e registrava todos os domicílios numa **Folha de Coleta**. Para a maioria dos domicílios preenchia um questionário curto. Esse questionário curto é o **universo** do censo, e é dele que saem as contagens totais de população, por sexo, idade, cor, nacionalidade e alfabetização.

Foi a primeira vez que um censo brasileiro usou amostragem na coleta. As perguntas longas — migração, instrução, estado conjugal, filhos tidos e vivos, rendimento, ocupação, ramo de atividade, e as características do domicílio como água, esgoto, fogão, rádio e geladeira — foram feitas a uma **amostra de 25%** dos domicílios, num questionário próprio, o **Boletim de Amostra** (formulário CD 2). O sorteio dessa amostra era sistemático e feito no campo, pela própria Folha de Coleta: os dois modelos de folha (CD 7 e CD 8) traziam impressas, em destaque, “Linhas de Amostra” a cada quatro linhas, e o domicílio registrado numa linha de amostra recebia o boletim longo. A posição da linha marcada mudava de página para página e de modelo para modelo, “de modo a permitir que todas as posições tivessem a possibilidade de constituírem Linhas de Amostra”; os dois modelos eram usados alternadamente conforme o setor tivesse número par ou ímpar, e a ordem de enumeração dos domicílios era fixada por regras, para que o recenseador não escolhesse quem entrava na amostra. Os volumes definitivos resumem: “vários processos foram adotados com a finalidade de proporcionar variação nas séries sistemáticas de seleção, de forma a evitar a introdução na amostra de tendências decorrentes de características cíclicas do universo” (Volume I, seção “Amostragem”). Essa amostra de 25% é a **amostra geral** do censo, e é dela que saíram os volumes definitivos publicados ao longo dos anos 1960 e 1970. Os seus microdados sobrevivem hoje para 17 unidades da federação, e o `censobr` os distribui na compilação de 1960.

A apuração mecânica de 25% do país levaria anos. Para publicar resultados rápidos, o IBGE sorteou, dentro da amostra de 25%, uma **subamostra de cerca de 1,27% da população**, perfurou-a em cartões e publicou com ela, em março de 1965, os *Resultados Preliminares do Censo Demográfico* (Série Especial, volume II). É dessa subamostra que trata este texto. Ela é a única amostra do Censo de 1960 que cobre todas as unidades da federação, e é por isso que ela importa mesmo onde a amostra de 25% existe: para onze unidades da federação (Rondônia, Acre, Amazonas, Roraima, Pará, Amapá, Maranhão, Piauí, Espírito Santo, Guanabara e Santa Catarina) ela é tudo o que resta do Censo de 1960 em microdados.

1.3 2. O vocabulário da época

Sem estas palavras o resto não se lê.

- **Boletim** — o questionário de um domicílio. O Boletim de Amostra (CD 2) tem a página do domicílio e uma linha por pessoa. No arquivo, cada boletim virou um cartão de família (a página do domicílio) e um cartão por pessoa.
- **Folha de Coleta** (CD 7 e CD 8) — a lista de todos os domicílios de um setor, na ordem em que o recenseador os visitou. As “linhas de amostra” impressas nela decidiam quem recebia o boletim longo.
- **Setor censitário** — a área de um recenseador, contínua e situada num só quadro (urbano, suburbano ou rural) de um só distrito. Os boletins de amostra de um setor ficavam juntos.
- **Pasta** — a palavra central deste texto. Quando os boletins de amostra chegavam ao órgão central, eram reunidos em lotes de trabalho de cerca de 250 boletins, na ordem dos setores, e cada lote era uma pasta física, numerada. A pasta é uma unidade administrativa (um pacote de papel que um codificador recebia), não uma unidade geográfica; mas, como os boletins entravam na ordem dos setores, uma pasta contém boletins de setores vizinhos, quase sempre do mesmo município, e é inteiramente urbana, inteiramente rural ou mista conforme os setores que a compõem. No desenho da subamostra, a pasta é a unidade sorteada: sorteou-se a pasta inteira.
- **Cadastro** — a lista completa das pastas de onde as sorteadas foram tiradas. Nenhum documento o publica; a seção 6 mostra como ele foi reconstruído.
- **Distrito** — a divisão administrativa abaixo do município (a sede é o distrito 01; os demais têm códigos ímpares, 03, 05, 07...). Na Guanabara, que era estado e cidade ao mesmo tempo, não há distritos: há bairros, circunscrições censitárias e favelas, com códigos próprios.
- **Zona fisiográfica** — a divisão regional que o IBGE usava dentro de cada estado (por exemplo, “Zona do Litoral”, “Zona da Mata”). Cada município pertence a uma zona. Ela importa porque, como a seção 6 mostra, o cadastro de sorteio foi ordenado por zona.
- **Situação** — do domicílio: quadro urbano, suburbano ou rural. “Urbano” nas tabelas de 1965 soma urbano e suburbano.
- **População presente e população residente** — presente é quem estava no domicílio na noite de referência (moradores presentes mais não moradores presentes); residente é quem mora ali (moradores presentes mais moradores ausentes). As tabelas de 1965 usam presente para pessoas e residente para domicílios.
- **Chave do questionário** — a identificação que o arquivo guarda para cada boletim: unidade da federação, distrito, número da pasta e número do boletim dentro da pasta. É por ela que a pasta é reconhecível no arquivo, e é ela que torna possível tudo o que a Parte II faz.
- **Cartão** — o cartão perfurado de 62 colunas em que cada pessoa e cada página de domicílio da subamostra foram gravadas em 1964. O arquivo de hoje é a imagem desse baralho de cartões.

1.3.1 2.1 Boletim, família e domicílio são três coisas diferentes

Esta distinção decide o que cada tabela conta, e é a primeira coisa a acertar, porque o vocabulário do censo de 1960 não é o de hoje.

O boletim é por família, não por domicílio. O recenseador preenchia um Boletim de Amostra para cada família: a página do domicílio na frente, uma linha por pessoa atrás. Onde duas famílias dividiam a mesma casa, saíam dois boletins — e a página do domicílio era preenchida **só no da família principal**. O boletim da segunda família traz essa página em branco, no papel e no arquivo (é a decisão registrada no *ipea/censobr#87*: ela fica em branco aqui também, porque copiá-la da família principal seria inventar dado).

Quem diz o que cada família é dentro do seu domicílio é o quesito V101:

V101	o que é	abre um domicílio?	famílias
1	família que ocupa o domicílio sozinha	sim	172.909
2	família principal de um domicílio com mais de uma	sim	348
3	domicílio coletivo	sim	835
4	segunda família do domicílio	não — entra no da anterior	345

V101	o que é	abre um domicílio?	famílias
5	terceira família	não — entra no da anterior	28
—	página de domicílio perdida na fita	sim, por não haver o que a prenda	151

O domicílio se reconstrói lendo o arquivo na ordem em que ele foi gravado: os códigos 1, 2 e 3 abrem um domicílio novo, e os códigos 4 e 5 entram no domicílio da família imediatamente anterior — o que funciona porque uma família convivente vem sempre logo depois da sua principal, 345 de 345 vezes.

Um exemplo torna isto concreto. Três boletins consecutivos com V101 igual a 1, 2 e 4 não são três domicílios: são dois. O primeiro é uma casa com uma família só; o segundo e o terceiro são **a mesma casa**, com duas famílias, e as perguntas sobre água, fogão e número de cômodos foram respondidas uma vez só, no segundo.

Daí os três números da subamostra, que são diferentes entre si e frequentemente confundidos:

- **897.009 pessoas;**
- **174.616 famílias** — isto é, boletins;
- **174.244 domicílios**, dos quais 173.899 têm uma família, 318 têm duas e 27 têm três.

A tabela de domicílios que este estágio entrega tem 174.245 linhas, uma a mais do que os domicílios que as pessoas apontam: o domicílio 127134 (São Paulo, pasta 63936, boletim 230) é um registro de família cujos cartões de pessoa se perderam por inteiro, e fica na tabela com as contagens de moradores em branco. É o único caso.

O peso é um por domicílio (seção 10.5), igual para todas as suas pessoas e para todas as suas famílias. Quem quiser a página do domicílio ao lado de cada pessoa junta as duas tabelas por `censobr_idhousehold`; quem quiser contar famílias usa `censobr_idfamily`.

1.4 3. O que os documentos da época dizem sobre o sorteio

1.4.1 3.1 O Volume II de 1965: a única descrição do desenho

A descrição do desenho da subamostra que existe é a do volume dos *Resultados Preliminares* (Série Especial, vol. II, março de 1965), na seção “Planejamento de amostragem” das páginas 10 e 11. Ela é curta o bastante para ser citada quase por inteiro. Primeiro o porquê:

“A adoção de um plano de grandes conglomerados coincidentes com as unidades naturais de trabalho se impunha dadas as condições expostas; além disso, grande parte dos itens selecionados para tabulação só constavam do Boletim de Amostra – CD-2; isto determinou que se optasse pelo desenho de uma sub-amostra da amostra geral selecionada na coleta censitária. A unidade de seleção da sub-amostra constituiu-se de ‘Pastas’ que reuniam Boletins de Amostra – CD-2. O plano utilizado corresponde por conseguinte ao de uma amostra bi-etápica em que a primeira etapa constituiu-se de uma amostra de cerca de 1/4 da população e a segunda etapa de cerca de 1/20 da etapa anterior; o que resultou em uma amostra de aproximadamente 1,27% do total da população e dos domicílios particulares.”

Depois as duas etapas:

“A primeira etapa foi formada pela amostra geral selecionada na coleta censitária, de uma forma ‘sistemática’, constando de aproximadamente 25% das pessoas recenseadas em domicílios particulares e coletivos. Compôs-se das pessoas recenseadas nos domicílios particulares registrados nas linhas previamente marcadas como pertencentes à amostra — uma em cada quatro linhas da folha de coleta — e de 25% das pessoas recenseadas em domicílios coletivos, selecionadas por processo equivalente ao adotado para os domicílios particulares.

Na segunda etapa estes conglomerados constituídos pelos domicílios da amostra geral estavam reunidos em lotes de trabalho denominados ‘Pastas’, de tamanho variável, com a média de 250 questionários, mantida a ordem de setores de coleta. As ‘Pastas’ foram estratificadas de acordo com critérios geográfico e de situação do domicílio, considerando-se em relação à situação destes 4 grupos: pastas com questionários de cidades de 100 000 e mais habitantes, pastas com questionários de aglomerados urbanos de menos de 100 000 habitantes, pastas com questionários de situação rural, e pastas mistas, contendo questionários de situação rural e urbana (quadro urbano e quadro suburbano).

A seleção das unidades de amostra foi sistemática, com início das séries aleatório. Foram selecionadas 814 pastas cujos questionários forneceram as informações que deram origem às estimativas apresentadas neste volume. Os cálculos de erros de amostragem para as características apresentadas estão sendo executados. Deixamos de incluí-los nesta publicação, a fim de evitar seu retardamento. Entretanto, farão parte de uma publicação especial em que se fará descrição detalhada do desenho da amostra e das técnicas utilizadas.”

O volume também explica para que a amostra foi dimensionada: “o fornecimento de dados globais para o País e para as três Regiões Fisiográficas mais populosas, de vez que a obtenção de dados para as Regiões de menores contingentes populacionais ou para as Unidades da Federação repercutiria no tamanho da amostra e no seu desenho”. As tabelas saem, por isso, para o Brasil e para as regiões Nordeste, Leste e Sul; o Norte e o Centro-Oeste só aparecem dentro do total do país.

Em nossas palavras, o desenho declarado é:

1. A primeira etapa é a própria amostra de 25%: os boletins de amostra do país inteiro, reunidos em pastas de cerca de 250 boletins cada, na ordem dos setores.
2. As pastas foram classificadas em **estratos**, definidos por dois critérios cruzados: um critério geográfico e a **situação** das pastas em quatro grupos — cidades com 100 mil habitantes ou mais; aglomerados urbanos menores; rurais; mistas.
3. Dentro de cada estrato, sorteou-se **uma pasta em vinte**, sistematicamente, com início aleatório: numa lista ordenada, escolhe-se um ponto de partida ao acaso entre as vinte primeiras e, a partir dele, toma-se uma pasta a cada vinte.
4. Todos os boletins da pasta sorteada entram na subamostra. Foram sorteadas **814 pastas**.

A fração de amostragem nominal é, portanto, $\frac{1}{4} \times \frac{1}{20} = \frac{1}{80} = 1,25\%$; o volume fala em “aproximadamente 1,27%” porque o número de boletins por pasta variava. O peso de desenho nominal, o inverso da fração, é 80: cada pessoa da subamostra representa oitenta pessoas.

Em figura:

todos os domicílios do país -> 1 em 4, na Folha de Coleta -> amostra de 25% (Boletins de Amostra CL
reunidos em pastas de ~250 boletins, r
classificadas em estratos: [critério g
-> 1 pasta em 20, sistemático, início alea
-> 814 pastas = a amostra de 1,27% (todos

Por que sortear pastas inteiras, e não pessoas? Porque era barato. As pastas já existiam como pacotes físicos; perfurar cartões para 814 pastas era um trabalho que cabia no calendário de uma publicação preliminar, e sortear pessoas espalhadas por milhares de pastas não cabia. O custo estatístico dessa escolha é o assunto da seção 12: as pessoas de uma mesma pasta são vizinhas e parecidas, e a amostra tem muito menos informação do que os seus 897 mil registros sugerem.

1.4.2 3.2 O que o Volume II não diz

Quatro coisas que a seção 3.1 deixa em aberto, e que a Parte II vai resolver ou decidir:

- **Qual é o critério geográfico dos estratos.** O texto diz “critérios geográfico e de situação” e não diz se o geográfico é a região, a unidade da federação, a zona fisiográfica ou outra coisa.
- **Como se operacionalizou “cidade de 100 000 e mais habitantes”.** O volume define “cidade” como sede municipal, mas não diz se o corte foi aplicado à população da cidade, à do município, ou à urbana do município, nem qual foi a fonte.
- **Como as pastas foram ordenadas** antes do sorteio sistemático, o que importa para saber se a ordem do cadastro pode ser usada no cálculo da variância.
- **Os erros de amostragem** e “a descrição detalhada do desenho”. A publicação especial prometida não existe na Biblioteca do IBGE, no Internet Archive nem nas citações dos volumes definitivos; os volumes definitivos, anos depois, prometem de novo “volume da Série Especial” com os erros de amostragem e “uma descrição detalhada do processo de amostragem”. Tudo indica que nenhum dos dois saiu.

1.4.3 3.3 Os outros documentos, e o que cada um acrescenta

Os tomos do Volume I (resultados definitivos, Série Regional, 19 tomos, um por unidade da federação). A introdução de cada tomo tem uma seção “Amostragem” que descreve a amostra de 25% — o que está resumido na seção 1 — e o método de estimativa usado nos resultados definitivos: estimativa de razão em **48 grupos**, formados depois da seleção por situação (urbana, rural), sexo, posição na família (chefe, cônjuge, outros; moradores ausentes à parte) e faixa de idade, com pesos inteiros escolhidos ao acaso entre as pessoas do grupo para que a soma reproduzisse a contagem do universo. Grupos com razão universo/amostra acima de 16 ou com menos de 100 pessoas no universo eram fundidos com o seguinte. Isso é o desenho da **amostra de 25%**, não desta subamostra, mas importa por duas razões: mostra que a amostra de 25% é, para efeito de variância, uma amostra sistemática de domicílios com efeito de desenho próximo de 1 (seção 13.2), e mostra que as margens do universo por unidade da federação existem publicadas, o que abre uma alternativa de calibração (seção 13.5).

Os dois grupos de tomos, e o que isso diz sobre a amostra de 25%. A “Apresentação” do volume nacional dos resultados definitivos (*Série Nacional*, vol. I) conta como a divulgação foi feita: “O plano de divulgação inicialmente estabelecido previa a apuração dos dados em duas etapas, sendo os resultados, para cada Unidade da Federação, apresentados em duas partes. De acordo com esse plano inicial, foram publicados os resultados definitivos relativos às seguintes Unidades da Federação: Rondônia, Roraima, Amapá, Acre, Amazonas, Pará, Maranhão, Piauí, Espírito Santo, Guanabara e Santa Catarina. A apuração dos dados correspondentes às Unidades da Federação restantes foi feita com base apenas no formulário CD.2 – Boletim de Amostra, tendo sido modificado o plano inicial, com a redução do número de tabelas e a reunião dos resultados em um único volume para cada Unidade da Federação. Os resultados apresentados, entretanto, abrangem todos os itens investigados.” Os tomos das onze primeiras unidades da federação saíram em duas partes ainda no Serviço Nacional de Recenseamento e nos primeiros anos da Fundação IBGE (a 1ª parte de Santa Catarina é datada de janeiro de 1968 e a 2ª, de novembro de 1968); os das outras dezessete saíram em volume único, na década de 1970, já sob a presidência de Isaac Kerstenetzky, e o volume nacional “encerra a apresentação dos resultados definitivos”. Duas consequências para este texto. Primeira: a amostra de 25% foi apurada e publicada para **todas** as unidades da federação, com o mesmo método de estimativa de razão em 48 grupos, ainda que os seus microdados só sobrevivam para dezessete — e as dezessete são exatamente as do segundo grupo, apuradas mais tarde e, tudo indica, já em computador, enquanto as onze do primeiro grupo, apuradas em equipamento de cartões, são as que hoje só têm esta subamostra. Segunda: nos tomos das dezessete, **as tabelas de sexo, idade, cor e alfabetização também são estimativas da amostra de 25%**, ancoradas nos totais da Sinopse Preliminar de 1961–1962 (população total, urbana e rural e domicílios, por município, apurados na contagem completa); só nos onze tomos do primeiro grupo essas tabelas vêm do universo. Isso importa para a calibração da seção 13.5.

O relatório do IPEA de abril de 1969 (*Processamento de uma amostra do Censo Demográfico de 1960*, 5 páginas datilografadas, cópia carbono de leitura difícil). Registra que o IPEA recebeu 29 caixas com cerca de 56 mil cartões — uma **subamostra** desta subamostra, para as regiões Nordeste, Leste e Sul, selecionada por grau de instrução do chefe da família —, que a dividiu em dez subamostras pelo último dígito do número de enumeração, excluiu não residentes, convidados e empregados e cartões com códigos impossíveis, e gravou tudo na fita magnética “IPEA 10” no Rio Datacentro da PUC-Rio. A página 4 lista o conteúdo de cada cartão de pessoa (situação, sexo e condição de presença, parentesco, idade, religião, cor, naturalidade, nacionalidade, procedência, tempo de residência, alfabetização, série concluída, curso, estado conjugal, ano do casamento, filhos tidos e vivos, rendimento, atividade, ocupação, ramo, posição na ocupação), que é exatamente o leiaute do arquivo de hoje. O relatório não descreve o desenho, mas prova

três coisas: que os cartões circularam fora do IBGE já em 1969, que o leiaute do cartão é o que o arquivo tem, e que o nosso arquivo (1.074.328 cartões) é o baralho inteiro, não a subamostra do IPEA.

O Volume IV da Série Especial (*Favelas — Estado da Guanabara*, 108 páginas). Publica as favelas cariocas por zona e circunscrição censitária. A sua seção “Amostragem” é idêntica à dos tomos do Volume I: vem dos resultados **definitivos** (amostra de 25% e universo), e não desta subamostra. Serve de gabarito para os domicílios em favelas que a subamostra identifica, não como fonte sobre o desenho.

O Código de Zonas Fisiográficas, Municípios e Distritos (situação em 1º-7-1960) e o **Anuário Estatístico do Brasil de 1961**. O primeiro dá o código oficial de cada município e distrito, que é o que o campo V116 do arquivo guarda, e a zona fisiográfica de cada município; o segundo dá a população total, urbana e rural de cada município em 1960. Os dois estão transcritos em `read_guides/1960_municipios.csv` e `read_guides/1960_distritos.csv`, e são o que permite classificar cada pasta por município, zona e tamanho da cidade.

O Volume II, o relatório do IPEA e o Volume IV estão em `references/fontes_1960/`, com um índice de procedência; os tomos do Volume I estão no Dropbox do projeto (seção 17).

1.5 4. O que sobreviveu no arquivo

A subamostra foi perfurada em cartões de 62 colunas, um por pessoa e um por página de domicílio. O arquivo de hoje, `HHOLDA.txt`, é a imagem desse baralho depois de décadas de cópias entre cartões, fitas e discos: 1.074.328 linhas de 62 caracteres. O documento de preparação descreve o dano (linhas deslocadas, caracteres corrompidos, blocos de cartões copiados duas vezes em Pernambuco, cartões de família perdidos) e o que se fez com ele. Aqui interessa o que o dano fez ao desenho:

- **Os conglomerados estão todos lá, e são 815.** O arquivo traz 817 chaves de pasta distintas, três a mais do que as 814 que o Volume II declara ter sorteado, e a diferença se decompõe assim. Uma é uma pasta de Rondônia gravada sob duas unidades da federação, que o passo 7 reúne. Duas são chaves danificadas, com **um domicílio cada**, que o passo 8 devolve à pasta certa: em 54-541 o cartão perdeu os dois últimos dígitos da pasta e guardou o distrito 18, que entre as três pastas 541xx da Guanabara só a 54142 tem; em 71-70382 o cartão está íntegro, mas a 70382 e a 70380 são as duas urbanas de Ponta Grossa, vizinhas no cadastro e no mesmo estrato — um sorteio de uma em vinte não tira as duas —, ela traz 1 dos 230 boletins que o cadastro lhe dá e o seu boletim 088 é justamente o que falta na 70380. As duas ficam marcadas em `censobr_diagnostico`, e pasta continua com o que o cartão gravou. Sobram **815**, uma a mais do que as 814 declaradas, e a diferença tem explicação. Ela não é uma pasta a mais: das 815, **670 estão nas dezessete unidades da federação que têm cadastro reconstruído, e todas as 670 foram encontradas nele** (seção 6.2), de modo que nenhuma é inventada; das 145 restantes, nas onze unidades sem cadastro, nenhuma se mostra espúria ao teste que pegou a do Paraná. O que sobra é uma questão de contagem, e o seu objeto é **Fernando de Noronha**.

Ali a única pasta *era* o cadastro inteiro, e o arquivo o demonstra: o fator de expansão implícito — a população publicada dividida pelo que o peso de desenho de 78,74 daria — é **0,06** em Noronha, cerca de um dezesseis avos, contra 0,95 em Roraima, 0,70 no Acre e 1,34 em Rondônia. Quer dizer que a pasta de Noronha não representa um vigésimo de um cadastro: representa o cadastro todo, e a fração real ali é 1/4, não 1/80. **Não houve sorteio de pasta em Fernando de Noronha**, e o Volume II diz que foram “selecionadas 814 pastas”.

$815 - 1 = 814$. O que fica sem prova documental é o que o IBGE efetivamente contou — nenhuma fonte diz se Noronha entrou na conta —, mas a ausência de sorteio ali é medida, não suposta, e nenhum candidato alternativo sobrevive. - **As pastas têm o tamanho esperado.** Mediana de 223 boletins por pasta (quartis 197 e 241, máximo 352), e mediana de 1.124 pessoas. Vinte e uma pastas têm menos de 100 boletins: as de Roraima e de Fernando de Noronha, que eram pequenas mesmo, e algumas truncadas. O caso grave é o Distrito Federal: as duas pastas de Brasília têm 77 e 60 boletins no arquivo, quando o cadastro reconstruído mostra que tinham 520 e 257 (seção 6) — restaram 15% e 23%. **Não são as únicas.** Confrontando cada pasta sorteada com o que o cadastro lhe dá, nas dezessete unidades da federação em que isso é possível, uma terceira perdeu mais do que elas: a pasta 31144, de Salvador, guarda **18 dos seus 247 boletins**, e os dezoito são os últimos, do 230 ao 247. Aqui o dano se lê com nitidez incomum: perdeu-se um bloco contíguo pela

cabeça da pasta, não cartões avulsos. Outras cinco pastas ficam entre 31% e 54% de cobertura; a mediana das demais é de 99%.

O que se perdeu em Brasília merece separar o que se sabe do que se infere, porque este texto afirmava mais do que a evidência dá. Sabe-se que as duas pastas perderam quatro quintos dos seus boletins. Sabe-se também que a construção civil é o **único ramo de atividade do quadro 3 de 1965 que não fecha** com a nossa contagem: -36% no Norte e Centro-Oeste, contra -2,7% no Leste e no Sul (documento de preparação, seção 7). E sabe-se, pela amostra de 25% — processada depois e para o mesmo Distrito Federal —, que **8.698 dos seus 14.818 boletins são boletins individuais de morador de domicílio coletivo**, sorteados pessoa a pessoa pela Lista CD 3: os alojamentos da obra. Daí a inferência de que o que falta é desproporcionalmente operário da construção, que é sólida. O que **não** se sabe é quais boletins a fita perdeu: nenhum registro diz isso, e a afirmação de que o trecho perdido “era um acampamento de operários” é leitura, não constatação. - **A chave do questionário sobreviveu em quase todas as linhas**, e é ela que permite dizer a que pasta cada pessoa pertence. Onde o cartão de família se perdeu, a chave está nos cartões de pessoa. - O resultado é uma tabela de **897.009 pessoas em 174.245 domicílios**, 885.127 delas presentes na noite de referência — 1,26% dos 70.119.071 presentes que o volume de 1965 publicou.

A distribuição das 815 pastas por unidade da federação, com a classificação de situação que a seção 7 justifica, dá a medida do que a amostra cobre e do que não cobre:

UF	pastas	cidade grande	urbana menor	mista	rural	boletins por pasta (mediana)
Rondônia	1	0	1	0	0	140
Acre	2	0	1	1	0	238
Amazonas	8	1	0	4	3	212
Roraima	4	0	2	0	2	17
Pará	16	4	1	7	4	222
Amapá	1	0	0	1	0	210
Maranhão	27	1	1	7	18	233
Piauí	14	1	1	3	9	219
Ceará	35	4	4	20	7	229
Rio Grande do Norte	13	2	1	6	4	227
Paraíba	23	2	3	9	9	233
Pernambuco	48	10	7	15	16	228
Fernando de Noronha	1	0	1	0	0	62
Alagoas	15	2	2	4	7	203
Sergipe	10	1	2	3	4	235
Bahia	70	8	8	33	21	224
Minas Gerais	112	9	23	54	26	212
Serra dos Aimorés	4	0	1	0	3	234
Espírito Santo	9	0	2	5	2	302
Rio de Janeiro	39	14	6	13	6	224
Guanabara	40	39	0	0	1	230,5
São Paulo	156	52	34	38	32	232
Paraná	47	4	7	17	19	225
Santa Catarina	23	0	5	12	6	221
Rio Grande do Sul	62	8	16	25	13	220
Mato Grosso	10	0	2	5	3	210
Goiás	23	1	3	11	8	201

UF	pastas	cidade grande	urbana menor	mista	rural	boletins por pasta (mediana)
Distrito Federal	2	0	2	0	0	68

Rondônia só tem Porto Velho; o Amapá tem uma pasta mista; o Acre, duas; Fernando de Noronha, uma; o Distrito Federal, duas pastas urbanas truncadas. Nenhum peso cria o que não foi sorteado: para essas unidades, a amostra descreve o que foi sorteado e sobreviveu, e nada mais (seção 15).

1.6 Parte II — A engenharia reversa do sorteio

Como não há publicação especial, o desenho teve de ser reconstruído a partir dos dados. A reconstrução andou em quatro passos, e cada um é apresentado com o que se perguntou, o que se mediu e o que se concluiu. O leitor que quiser só o resultado pode ir à seção 9; o que quiser conferir pode rodar `references/figuras/desenho_amostral_1960.R`, que refaz tudo o que está aqui.

1.7 5. Passo 1: o que a amostra de 1,27% diz sozinha

A primeira pergunta foi se a chave do questionário — em particular o **número da pasta** — carregava alguma informação sobre o sorteio. Carrega, e muita.

1.7.1 5.1 Os números das pastas são todos pares

As 815 pastas têm **todas** número par — a única ímpar do arquivo era a chave danificada da Guanabara, devolvida à sua pasta (seção 4). Isso diz que as pastas da amostra de 25% foram numeradas de dois em dois, e que o número da pasta sorteada é o número que ela tinha no cadastro inteiro, não uma numeração nova dada às sorteadas. Os números também carregam a unidade da federação como prefixo: as pastas do Ceará vão de 14002 a 15426, as da Bahia de 31002 a 33786, as de São Paulo de 60002 a 66292. Cada unidade da federação tem a sua própria numeração, e ela não atravessa fronteiras.

1.7.2 5.2 A grade de 40 nas cidades grandes

Se o sorteio foi de uma pasta em vinte numa lista numerada de dois em dois, duas pastas sorteadas consecutivas de uma mesma série devem diferir em 40 no número.

Antes de olhar os números, um aviso sobre a régua, porque esta seção e a seção 7 medem a mesma coisa com régua diferentes e o leitor que não perceber isso vai achar que elas se contradizem. Aqui a distância entre duas pastas sorteadas é medida em **números de pasta**, e o valor esperado é 40. Na seção 7, com o cadastro em mãos, ela passa a ser medida em **posições dentro da sublista do estrato** — ordena-se só as pastas daquele estrato, numera-se 1, 2, 3... — e o valor esperado é 20.

As duas régua coincidem num caso só: quando as pastas do estrato são contíguas no cadastro, andar 20 posições é andar 40 no número. Isso vale para as cidades grandes, cujas pastas vêm todas juntas no começo da numeração de cada unidade da federação. Não vale para os outros três grupos, cujas pastas estão **intercaladas** com as dos demais ao longo de todo o cadastro: ali, 20 posições adiante podem ser 80, 140 ou qualquer outro número. A consequência é que a medida desta seção **não tem como enxergar** o salto sistemático fora das cidades grandes — não porque ele não

exista, mas porque a régua é a errada. O que a seção 5.2 decide, portanto, é só o caso das cidades grandes; os outros três grupos ficam indecisos até a seção 7.

A figura 1 mostra os números das pastas sorteadas de quatro unidades da federação, com cada pasta classificada num dos quatro grupos de situação do Volume II (pela situação dos seus próprios boletins e pelo tamanho do município — a regra exata está na seção 8):

As pastas sorteadas, pelo número: cada grupo de situação é uma sequência própria

Um traço por pasta sorteadas. As de cidade grande caem numa grade regular; os outros grupos têm grades próprias, intercaladas.




Figura 1: Os números das pastas sorteadas em quatro unidades da federação, por grupo de situação

Três coisas se veem a olho nu. As pastas das cidades grandes estão no começo da numeração de cada unidade da federação (as capitais foram as primeiras pastas do cadastro, como a seção 6 confirma) e caem numa grade regular. As pastas mistas e rurais ocupam o resto da numeração, intercaladas umas com as outras — e ali, pelo que já se disse sobre a régua, nenhuma grade tem como aparecer. E as pastas de um mesmo grupo nunca se aproximam demais umas das outras, o que é a assinatura de séries sistemáticas separadas, uma por grupo de situação.

A figura 2 mede isso: para cada grupo, o histograma da diferença entre os números de duas pastas sorteadas consecutivas da mesma unidade da federação.

grupo de situação	pares de pastas consecutivas	diferença exatamente 40	40, 42, 44 ou 46	diferença mediana
cidade grande	145	72%	79%	40
urbana menor	111	1%	1%	140
mista	271	0%	2%	80
rural	200	1%	2%	110

Nas cidades grandes, cujas pastas são contíguas no cadastro, a grade é quase perfeita. Município a município, entre os que têm quatro ou mais pastas de cidade grande:

Só com a amostra de 1,27%: o pico em 40 (vinte pastas pares) nas cidades grandes
 Traçado: 40. Nos outros grupos a grade existe, mas os números das pastas do grupo estão intercalados com os dos demais.




Figura 2: A diferença entre os números de duas pastas sorteadas consecutivas, por grupo

cidade	pastas	diferenças entre números consecutivos
Rio de Janeiro (Guanabara)	39	37 vezes 40 e uma vez 82
São Paulo	39	21 vezes 40; 44 ou 46 seis vezes; onze saltos de 50 a 82 onde a numeração pulou
Recife	9	40 40 40 42 44 40 44 40
Salvador	8	40 40 40 40 40 40 40
Belo Horizonte	8	40 40 40 40 40 40 40
Porto Alegre	7	40 40 40 40 40 40
Belém	4	40 40 40
Fortaleza	4	40 40 42
Curitiba	4	40 40 40

Nos outros três grupos a diferença mediana é de 80 a 140, e quase nunca 40: não porque o sorteio ali fosse outro, mas porque os números das pastas rurais, mistas e urbanas menores estão intercalados no cadastro, de modo que entre duas rurais sorteadas há muitas pastas de outros grupos. Quando se ignora o grupo e se olha só a unidade da federação, apenas 16% das diferenças são 40.

O que o passo 1 estabelece, então, é mais modesto do que parece: nas cidades grandes o sorteio andou de vinte em vinte numa série própria, e os quatro grupos de situação são séries separadas, porque as pastas de um grupo nunca se aproximam das do outro. Que o mesmo salto de vinte exista dentro dos outros três grupos é plausível mas **não está demonstrado aqui** — a régua desta seção não alcança. Quem demonstra é a seção 7, com o cadastro.

1.7.3 5.3 O peso realizado bate com o nominal

Uma segunda verificação independente do “uma em vinte” é o fator de expansão implícito: a população presente que o IBGE publicou em 1965, dividida pela contagem do arquivo. Se a fração for de fato 1/80 e o arquivo estiver íntegro, o fator é 80.

domínio	publicado em 1965	peças presentes no arquivo	fator implícito
Brasil	70.119.071	885.127	79,2
Brasil, urbana	32.471.377	406.021	80,0
Brasil, rural	37.647.694	479.106	78,6
Nordeste	15.524.609	195.288	79,5
Leste	24.659.232	311.219	79,2
Sul	24.445.902	307.859	79,4
Norte e Centro-Oeste	5.489.328	70.761	77,6

O urbano dá 79,5 a 80,1 em todas as regiões; o rural dá um pouco menos (76,3 a 79,3), e o Norte e Centro-Oeste dá 77,6, puxado pelo Distrito Federal truncado. A fração nominal está confirmada, e o desvio para baixo é o dano do arquivo, não o desenho.

1.7.4 5.4 O que ficou em aberto depois do passo 1

O passo 1 confirma o sorteio sistemático de uma em vinte por grupo de situação, mas não responde à pergunta que mais importa para a variância: **qual era o critério geográfico dos estratos**. A numeração não atravessa unidades da federação, então ela não distingue entre “cada unidade da federação é um estrato” e “cada região é um estrato” — nos dois casos as pastas de uma unidade da federação formam sequências próprias. E ela não diz onde começa e termina cada estrato, porque só se veem as sorteadas, não as que não foram.

1.8 6. Passo 2: o cadastro de sorteio, reconstruído a partir da amostra de 25%

1.8.1 6.1 A ideia

A resposta veio de onde não se esperava. A compilação da amostra de **25%** do Censo de 1960 que o censobr distribuiu guarda, para cada domicílio, o número da pasta em que o seu boletim foi arquivado (v001). Como essa amostra é a amostra geral inteira — todos os boletins de amostra, não só os das pastas sorteadas —, os seus números de pasta são **o cadastro completo**: a lista de onde as 814 pastas foram tiradas. Para as 17 unidades da federação em que a amostra de 25% sobreviveu, isso permite refazer o sorteio e olhá-lo por dentro: ver todas as pastas, marcar as sorteadas, e perguntar em que lista ordenada elas caem de vinte em vinte.

1.8.2 6.2 O cadastro

O cadastro reconstruído tem **13.411 pastas**, com mediana de 235 boletins por pasta (quartis 216 e 250), a média de 250 que o Volume II declara. A sua composição por grupo de situação é 4.989 mistas, 3.610 rurais, 2.432 de cidade grande e 2.380 urbanas menores. Por unidade da federação:

UF	pastas no cadastro	pastas sorteadas	cadastro / sorteadas	números de pasta
Ceará	706	35	20,2	14002 a 15426
Rio Grande do Norte	266	13	20,5	17002 a 17532
Paraíba	461	23	20,0	19000 a 20034
Pernambuco	968	48	20,2	21002 a 22936

UF	pastas no cadastro	pastas sorteadas	cadastro / sorteadas	números de pasta
Fernando de Noronha	1	1	1,0	27002
Alagoas	300	15	20,0	25002 a 25600
Sergipe	195	10	19,5	30002 a 30390
Bahia	1.392	70	19,9	31002 a 33786
Minas Gerais	2.229	112	19,9	40002 a 44462
Serra dos Aimorés	74	4	18,5	50002 a 50148
Rio de Janeiro	764	39	19,6	52002 a 53530
São Paulo	3.140	156	20,1	60002 a 66292
Paraná	945	47	20,1	70002 a 71900
Rio Grande do Sul	1.265	62	20,4	81002 a 83532
Mato Grosso	211	10	21,1	91002 a 91424
Goiás	456	23	19,8	94002 a 94914
Distrito Federal	38	2	19,0	97002 a 97076

Quatro fatos saem da tabela:

1. **Todas as 670 pastas** que a subamostra tem nessas 17 unidades da federação estão no cadastro. Nenhuma pasta “inventada”, nenhuma chave inconsistente.
2. **A razão entre o cadastro e as sorteadas é 20 em toda parte** — de 18,5 (Serra dos Aimorés, 4 pastas) a 21,1 (Mato Grosso, 10), mediana 19,9. É a confirmação direta e independente do “uma pasta em vinte”, e é também a prova de que o sorteio foi feito **separadamente em cada unidade da federação**: se a série sistemática atravessasse fronteiras, a razão por unidade da federação flutuaria muito mais do que isso nas pequenas. Fernando de Noronha, com uma única pasta no cadastro e ela sorteadas, é a exceção que confirma: ali não houve sorteio possível.
3. **As sorteadas não são maiores nem menores que as demais**: mediana de 235 boletins nas duas. O sorteio não foi enviesado por tamanho.
4. **O Distrito Federal**: as duas pastas sorteadas têm 520 e 257 boletins no cadastro, e 77 e 60 no arquivo da subamostra. É daqui que vem a certeza de que o arquivo as truncou.

1.8.3 6.3 Como o cadastro está ordenado

O sorteio sistemático depende da ordem da lista. Percorrendo o cadastro de cada unidade da federação na ordem do número da pasta e contando quantas vezes cada atributo muda de uma pasta para a seguinte:

UF	pastas	zonas fisiográficas	mudanças de zona	municípios	mudanças de município	mudanças de grupo de situação
São Paulo	3.140	70	70	503	502	1.048
Minas Gerais	2.229	56	56	483	482	1.008
Bahia	1.392	26	26	194	193	648
Rio Grande do Sul	1.265	20	20	150	149	468
Pernambuco	968	15	15	102	101	438
Paraná	945	21	21	162	161	461
Rio de Janeiro	764	12	12	61	60	218
Ceará	706	22	21	142	141	305
Paraíba	461	12	11	88	87	236
Goiás	456	25	25	179	178	235

A leitura: **o cadastro é ordenado por zona fisiográfica e, dentro dela, por município**. Cada município é um bloco contíguo de pastas (502 mudanças para 503 municípios em São Paulo é o mínimo possível: uma mudança a cada município novo), e cada zona é um bloco contíguo de municípios — com uma exceção regular: a zona da capital aparece em dois blocos, porque **as pastas da capital vêm primeiro no cadastro** e o resto da sua zona vem na posição natural. Em São Paulo, a zona 623 ocupa as posições 1 a 965 (965 pastas, 833 delas puramente urbanas de cidade grande) e depois as posições 1643 a 1799; em Minas, a zona de Belo Horizonte ocupa as posições 1 a 171 e depois 1610 a 1639. A figura 3 mostra isso para São Paulo:

O cadastro é ordenado por zona fisiográfica: cada zona é um bloco contíguo de pastas
Cada segmento é um bloco de pastas consecutivas da mesma zona: 71 blocos para 70 zonas.




Figura 3: Cada zona fisiográfica é um bloco contíguo do cadastro de São Paulo

A situação, ao contrário, **não** ordena o cadastro: o grupo muda 1.048 vezes em São Paulo, embora só existam quatro grupos. As pastas urbanas, rurais e mistas estão intercaladas ao longo de todo o cadastro, porque a ordem é a dos setores dentro de cada município, e um município tem setores urbanos e rurais. A figura 4 mostra o cadastro inteiro da Bahia, com as sorteadas em cor:

“A situação não ordena o cadastro” é a frase que mais confunde neste texto, e vale desdobrá-la, porque dela depende tudo o que vem a seguir. Ordenar uma lista é escolher por qual chave ela é classificada. As chaves do cadastro são zona fisiográfica, depois município, depois setor — e mais nada. A situação **não é chave**: ela é apenas um atributo que cada pasta carrega, e que varia de uma pasta para a seguinte porque um município tem setores urbanos e setores rurais, e as pastas foram formadas na ordem em que os setores chegaram.

O que a estratificação por situação fez, portanto, não foi reordenar coisa alguma. Foi **recortar quatro sublistas** da lista já ordenada — as pastas de cidade grande, as urbanas menores, as rurais e as mistas, cada uma na ordem em que aparecem — e sortear uma em vinte dentro de cada sublista, com um ponto de partida próprio. Em esquema, com U, M e R para os grupos, e as sorteadas entre colchetes:

```
cadastro da UF (ordem: zona -> municipio -> setor)
pasta    02 04 06 08 10 12 14 16 18 20 22 24 26 28 30 32 34 36 ...
```

O cadastro reconstruído: todas as pastas da Bahia (cinza) e as sorteadas (cor)

As pastas dos quatro grupos estão intercaladas ao longo de todo o cadastro; dentro de cada grupo, as sorteadas caem de 20 em 20.




Figura 4: O cadastro inteiro da Bahia, com os quatro grupos intercalados e as sorteadas em cor

grupo U R M U R R M U R M U U R M R U M R

a sublista rural, e so ela, numerada de 1 em diante

pasta 04 10 12 18 26 30 36 ... <- as mesmas pastas, na mesma ordem

posicao 1 2 3 4 5 6 7 ... <- aqui o sorteio anda de 20 em 20

Veja o que isso faz com a medida da seção 5.2. Duas pastas rurais sorteadas estão a vinte **posições** uma da outra na sublista rural; mas entre elas, no cadastro, passaram dezenas de pastas urbanas e mistas, de modo que a diferença entre os seus **números** pode ser 80, 140 ou qualquer coisa. O salto existe; é a régua que não o alcança.

A figura 5 mostra isso com dados reais, nas duas régua, para as pastas rurais da Bahia — 427 no cadastro, 21 sorteadas. Os espaçamentos falam por si. **Em posição dentro da sublista rural:**

20 20 20 20 20 20 20 20 20 20 20 20 17 20 20 20 20 20 20 20

Os mesmos vinte intervalos, medidos em número de pasta:

96 138 104 118 90 70 62 76 120 86 92 130 172 154 74 192 156 190 104 98

É o mesmo sorteio, visto de duas maneiras. A primeira linha é um relógio; a segunda parece ruído.

Isto importa por duas razões. Primeiro, é assim que se deve ler “estratificadas de acordo com critérios geográfico e de situação”: a estratificação por situação não reordenou o cadastro; ela apenas separou, dentro da lista já ordenada por zona e município, quatro sublistas — e em cada sublista se sorteou uma em vinte. Segundo, a ordem por zona e município é o que torna a amostra sistemática melhor do que uma amostra aleatória de pastas (pastas vizinhas na lista são vizinhas no mapa), e o que justifica o estimador de diferenças sucessivas da seção 13.4.

1.9 7. Passo 3: em que estrato o sorteio foi feito?

1.9.1 7.1 O teste

Com o cadastro em mãos, a pergunta “qual era o estrato?” vira uma pergunta com resposta empírica. O raciocínio:

O salto de vinte só aparece quando se olha dentro do estrato

As 427 pastas rurais da Bahia, com as 21 sorteadas em cor.




Figura 5: As pastas rurais da Bahia nas duas réguas: irregular na numeração do cadastro, de vinte em vinte dentro do estrato

Se o sorteio foi sistemático de uma em vinte **dentro de um estrato**, então, ordenando o cadastro daquele estrato (e só dele) e numerando as pastas de 1 em diante, as posições das sorteadas formam uma progressão aritmética de razão 20: $a, a + 20, a + 40, \dots$, com a sorteado entre 1 e 20. Logo, para cada estratificação candidata, basta medir a fração dos pares de sorteadas consecutivas cujo espaçamento em posições é **exatamente 20**. A estratificação verdadeira produz espaçamentos de 20; uma estratificação errada, não.

Um exemplo de brinquedo mostra por que estratificações erradas falham nos dois sentidos. Suponha um cadastro de 80 pastas de uma unidade da federação, 40 urbanas (U) e 40 rurais (R), intercaladas, e que o IBGE sorteou uma em vinte dentro de cada grupo: nas urbanas, começando pela 5ª urbana (posições 5 e 25 dentro da lista urbana); nas rurais, começando pela 12ª rural (12 e 32).

cadastro (uma UF, 80 pastas, U e R intercaladas): U R U U R R U R U R U U R R U R ...

lista urbana (40): U1 U2 U3 U4 [U5] U6 ... U24 [U25] U26 ... U40 espaçamento = 20 <- estrato

lista rural (40): R1 R2 ... R11 [R12] R13 ... R31 [R32] R33 ... R40 espaçamento = 20 <- estrato

lista da UF (80): as 4 sorteadas caem em posicoes como 9, 23, 47, 66 espaçamentos 14, 24, 19: nada

Se a estratificação candidata for **grossa demais** (juntar U e R), as posições das sorteadas na lista conjunta dependem de quantas pastas do outro grupo se intrometem entre elas, e o espaçamento vira qualquer número. Se for **finha demais** (por exemplo, quebrar a lista urbana em duas metades), os pares que ficam dentro de cada metade continuam espaçados de 20 — a estratificação fina não é refutada pelos pares que sobrevivem —, mas ela perde os pares que atravessam a fronteira, e são justamente esses que distinguiriam uma lista contínua de duas listas com inícios aleatórios independentes. Por isso o teste tem dois lados: a fração de espaçamentos exatos e o número de pares que a estratificação candidata consegue medir.

1.9.2 7.2 As candidatas

Cada estratificação foi testada com o mesmo cadastro, a mesma classificação das pastas e as mesmas sorteadas:

estratificação candidata	estratos	pares medidos	espaçamento exatamente 20	entre 19 e 21	espaçamento mediano
zona fisiográfica × situação (4 grupos)	891	184	85,3%	89,1%	20
unidade da federação × situação (4 grupos)	60	612	77,3%	90,4%	20
unidade da federação × ur- bana/rural/mista (3 grupos)	48	624	74,7%	87,5%	20
região × situação (4 grupos)	16	654	72,6%	85,2%	20
unidade da federação × município	2.344	160	44,4%	48,1%	20
zona fisiográfica, sem situação	312	420	18,1%	23,1%	18
unidade da federação, sem situação	17	653	12,1%	18,2%	20
região, sem situação	4	666	11,9%	18,0%	20

A leitura, de baixo para cima:

- **Sem a situação, o padrão desaparece.** Unidade da federação sozinha dá 12,1% de espaçamentos exatos; região sozinha, 11,8%; zona sozinha, 18,1%. Isso é o que se espera do acaso quando as sorteadas de quatro séries independentes são olhadas numa lista só (a figura 6, painel de cima, mostra a distribuição espalhada). A situação entra na estratificação, como o Volume II diz.
- **Com a situação, o padrão aparece,** e ele é mais nítido com a unidade da federação (77,3%) do que com a região (72,6%). A diferença entre as duas são exatamente os pares que se quebram quando as unidades da federação de uma mesma região são emendadas numa lista só: em “região × situação” a lista rural do Nordeste é Maranhão, depois Piauí, depois Ceará..., e a cada fronteira o espaçamento deixa de ser 20 porque cada unidade da federação recomeçou a sua série com o seu próprio início aleatório. É o mesmo mecanismo do exemplo de brinquedo, agora entre unidades da federação.
- **Os quatro grupos são melhores que três.** Separar as cidades grandes das outras pastas urbanas sobe de 74,7% para 77,3%. O quarto grupo existia, como o Volume II diz.
- **A zona fisiográfica não é o estrato,** embora “zona × situação” tenha a maior fração de exatos. É o caso “fino demais” do exemplo de brinquedo: com 891 estratos, essa candidata só consegue medir 185 pares — os que caem dentro de uma mesma zona —, e esses pares saíam exatos de qualquer maneira, porque a zona é um bloco contíguo do cadastro da unidade da federação (seção 6.3) e uma progressão de razão 20 continua sendo de razão 20 dentro de qualquer bloco contíguo. O que decide são os pares que **atravessam** a fronteira de uma zona: se cada zona fosse um estrato com início aleatório próprio, esses pares teriam espaçamento arbitrário e só por acaso (cerca de 5% das vezes) cairiam em 20. Medido: dos 598 pares de “UF × situação” em que as duas pastas têm zona conhecida, os 167 que ficam dentro de uma zona são 85,6% exatos, e os **431 que atravessam zonas são 73,3% exatos** — catorze vezes mais do que o acaso daria. As séries continuam através das zonas; a zona ordena o cadastro, mas não o estratifica. O mesmo vale para o município (44,4% com 160 pares), pelo mesmo motivo.

Qual era o estrato? O espaçamento entre sorteadas só vira 20 quando o estrato cruza UF e situação
Sorteio sistemático de uma em vinte dentro do estrato certo produz espaçamentos exatamente iguais a 20.




Figura 6: O espaçamento das sorteadas sob cada estratificação candidata

1.9.3 7.3 Unidade da federação × situação, de perto

Dentro da estratificação vencedora, a distribuição dos 612 espaçamentos é concentrada em 20 e simétrica em volta dele: 473 valem 20, 41 valem 21, 39 valem 19, 12 valem 18, 7 valem 17, 5 valem 22. Por grupo de situação:

grupo	pares	exatamente 20	entre 19 e 21
cidade grande	105	92%	94%
urbana menor	108	81%	91%
mista	236	74%	91%
rural	163	70%	87%

E, olhados um a um, os estratos são bonitos de ver. Cada um começa num ponto próprio, sorteado ao acaso entre 1 e 20, e daí anda de vinte em vinte (a posição é a da pasta no cadastro do estrato):

```

Bahia, cidade grande (cadastro de 153, 8 sorteadas): 12 32 52 72 92 112 132 152
Bahia, urbana menor (cadastro de 170, 8 sorteadas): 19 39 59 79 99 119 139 159
Bahia, rural (cadastro de 427, 21 sorteadas): 12 32 52 72 92 112 132 152 172 192 212 232
Bahia, mista (cadastro de 642, 33 sorteadas): 6 26 46 66 86 106 126 146 166 186 206 226
São Paulo, cidade grande (cadastro de 1.074, 54 sorteadas): 19 39 59 79 99 119 139 159 179 199 219 239 259 279 299 319 339 359 379 399 419 439 459 479 499 519 539 559 579 599 619 639 659 679 699 719 739 759 779 799 819 839 859 879 899 919 939 959 979 999
Minas Gerais, rural (cadastro de 531, 26 sorteadas): 2 21 41 61 81 101 121 141 161 181 201 220
Pernambuco, mista (cadastro de 315, 15 sorteadas): 24 47 67 82 102 122 142 162 182 202 222 242

```

Dentro de cada estrato UF × situação, as sorteadas andam de vinte em vinte

Pontos: as pastas sorteadas. Tracejado: a reta de inclinação 20 que parte da primeira sorteada — o início aleatório da série.




Figura 7: As posições das sorteadas dentro de cada estrato, de vinte em vinte a partir de um início próprio

Os inícios — 12, 19, 12, 6, 19, 2, 24 — são o “início das séries aleatório” que o Volume II menciona numa linha e nunca explica. A razão cadastro/sorteadas por estrato tem mediana 19,9, com quartis 19,1 e 21,3.

O que a imperfeição significa. Dos 60 estratos candidatos, 58 têm pastas sorteadas e 48 têm três ou mais; desses 48, 25 têm 80% ou mais de espaçamentos exatos e 14 são perfeitos. Os desvios de uma unidade (19 ou 21, que somam 13% dos pares) são o que se espera quando **uma pasta do cadastro está classificada num grupo diferente do que o IBGE lhe deu**: uma pasta a mais ou a menos na lista desloca em um todas as posições seguintes. A nossa classificação usa a situação dos boletins da amostra de 25% e o tamanho do município; a do IBGE usou os boletins físicos e uma tabela que não temos; discordâncias pontuais são inevitáveis. Os desvios maiores concentram-se em três unidades da federação do Nordeste — Paraíba, Ceará e Rio Grande do Norte, onde os estratos rurais e mistos ficam entre 17% e 42% de exatos, e o urbano menor da Paraíba, com três pastas, em 0% — e no rural do Rio Grande do Sul (42%); em quatro estratos a primeira sorteadada está além da posição 20 (Porto Alegre começa em 38), o que indica que ali uma pasta sorteadada está classificada em outro grupo ou faltou no cadastro. Não se sabe se a causa é a classificação ou a compilação da amostra de 25% nessas unidades; o efeito sobre a variância é pequeno, porque o estrato errado de uma pasta muda pouco a soma de quadrados, e é conservador, porque a aproximação errada é sempre para um estrato mais grosso.

Uma última confirmação, de outra natureza: as **corridas** de espaçamentos exatamente 20 — sequências de sorteadas consecutivas, todas a 20 uma da outra — nunca misturam grupos de situação (por construção do teste) e **atravessam zonas fisiográficas com toda a naturalidade**: das 104 corridas com duas ou mais pastas, 97 passam por mais de uma zona. Se a zona fosse estrato, uma corrida acabaria em cada fronteira de zona.

1.10 8. Passo 4: como o IBGE separava a “cidade de 100 000 e mais habitantes”?

O Volume II diz que o primeiro grupo é o das “pastas com questionários de cidades de 100 000 e mais habitantes”, e noutra seção define cidade como a sede do município. Não diz que população usou nem de que fonte. O corte não se deduz da própria amostra: um município que recebeu uma pasta inteira já aparenta ter 90 mil habitantes (uma pasta $\times$ 80), e a estimativa acusaria mais de duzentos municípios acima de 100 mil. O tamanho tem de vir de fora: a população total, urbana e rural de cada município em 1960, publicada no Anuário Estatístico de 1961 e transcrita em `read_guides/1960_municipios.csv`.

O mesmo teste da seção 7 decide entre as definições: fixa-se “UF $\times$ situação” e troca-se só a regra do quarto grupo, vendo qual delas produz a progressão mais limpa.

definição de “cidade grande” (pasta puramente urbana de município com...)	estratos	pares	exatamente 20	entre 19 e 21
população urbana $\geq$ 100 mil	60	612	77,3%	90,4%
população urbana $\geq$ 200 mil	56	616	75,5%	88,3%
não separar cidades grandes (3 grupos)	48	624	74,7%	87,5%
população total $\geq$ 100 mil	60	612	72,9%	85,9%
população urbana $\geq$ 50 mil	61	611	69,1%	82,0%

A população **urbana** do município no corte de 100 mil é a definição que melhor reproduz o sorteio, e o grupo “cidade grande” é justamente o de ajuste mais alto (92% de espaçamentos exatos, contra 70% a 79% dos outros três). A população total do município seria pior do que não separar as cidades: ela promove a cidade grande municípios extensos de sede pequena, que o IBGE claramente não tratava assim. São 34 os municípios com população urbana de 100 mil ou mais em 1960 — de São Paulo e Rio de Janeiro (3,3 e 3,2 milhões) a Olinda e Teresina (100 mil) — e todos os 34 têm pasta de cidade grande na amostra.

Fica uma ressalva honesta: “população urbana do município” não é exatamente “população da cidade” (ela inclui as vilas, sedes de distrito), e o IBGE pode ter usado uma lista própria. Mas nenhuma outra definição testada chega perto, e a diferença prática entre “urbana do município” e “da cidade” no corte de 100 mil é nula para as 34 cidades em questão.

1.11 9. O desenho, reconstruído

Juntando os quatro passos, o desenho da amostra de 1,27% é:

- **Primeira etapa:** um domicílio em quatro, sistematicamente, na Folha de Coleta de cada setor — a amostra de 25%.
- **Cadastro:** os boletins de amostra de cada unidade da federação, reunidos em pastas de cerca de 250 na ordem dos setores, e as pastas numeradas de dois em dois na ordem zona fisiográfica → município → setor, com as pastas da capital em primeiro lugar.
- **Estratos:** a unidade da federação cruzada com quatro grupos de situação da pasta — puramente urbana de município com população urbana de 100 mil ou mais; puramente urbana dos demais municípios; puramente rural; mista.
- **Segunda etapa:** em cada estrato, uma pasta em vinte, sistematicamente, com início aleatório próprio; todos os boletins da pasta sorteada.
- **Resultado:** 1,27% da população, em **815 unidades primárias** no arquivo — as 814 pastas que o Volume II declara ter sorteado, mais a de Fernando de Noronha, que não foi sorteada porque era o cadastro inteiro (seção 4).

O que é fato documentado, o que é demonstrado e o que é escolha:

afirmação	natureza	fonte
duas etapas, 1/4 e 1/20; pastas de ~250 boletins na ordem dos setores; 4 grupos de situação; sistemático com início aleatório; 814 pastas a fração é 1/20 em cada unidade da federação	fato documentado	Volume II, 1965, pp. 10–11
o critério geográfico é a unidade da federação	demonstrado	seção 6.2: razão cadastro/sorteadas 18,5 a 21,1
a zona e o município ordenam o cadastro mas não o estratificam	demonstrado	seção 7.2: 77,3% contra 72,6% (região) e 12,1% (sem situação)
“cidade de 100 000 e mais” = população urbana do município no Anuário	melhor definição testada	seções 6.3 e 7.2: pares através de zonas 73,3% exatos seção 8
a classificação de cada pasta nos quatro grupos	escolha nossa, pela situação dos boletins da própria pasta	seções 7.3 e 11
a extensão do critério às 11 unidades da federação sem amostra de 25%	escolha nossa, sem verificação possível	seção 11
a regra de colapso dos estratos com uma pasta só	escolha nossa	seção 11

1.12 Parte III — Pesos, colunas de desenho e erros amostrais

1.13 10. Os pesos

As tabelas trazem três pesos por domicílio, iguais para todas as suas pessoas: o peso de desenho (`censobr_weight_desenho`), o peso final, calibrado aos resultados definitivos do censo (`censobr_weight`, com o seu fator `censobr_weight_fator`), e o peso calibrado aos resultados preliminares de 1965 (`censobr_weight_1965`, com `censobr_weight_1965_fator`). Esta seção explica cada um, por que há dois pesos calibrados e o que cada um reproduz.

1.13.1 10.1 O peso de desenho

Cada domicílio da subamostra recebe o inverso da fração de amostragem que o Volume II declara:

$$w^d = \frac{1}{0,0127} = 78,74$$

Se o arquivo fosse íntegro e a fração exata em toda parte, bastaria multiplicar contagens por esse número para estimar totais do país; a seção 5.3 mostrou que o fator realizado é de fato 79 a 80 nos domínios grandes. Há uma exceção conhecida: em Fernando de Noronha a única pasta sorteada era o cadastro inteiro (a amostra de 25% mostra uma pasta em vez de vinte, seção 6.2), de modo que ali só houve a etapa de um domicílio em quatro e o peso de desenho verdadeiro é 4, não 78,74. Isso se confere boletim a boletim: **os 62 domicílios da pasta de 1,27% estão todos entre os 75 da amostra de 25%** — a pasta era mesmo o cadastro, e o arquivo de 1,27% perdeu 13 deles. A coluna `censobr_weight_desenho` guarda os 78,74 nominais em toda parte, e por isso `censobr_weight_fator` sai entre 0,05 e 0,09 em Noronha; o peso final parte dos 4, e em relação a eles o fator fica entre 0,94 e 1,79, com mediana 4,52 de peso.

1.13.2 10.2 Por que calibrar, e a quê

O arquivo não é íntegro (pastas truncadas, cartões perdidos, cópias removidas), a fração real variou por estrato, e há totais publicados que a amostra deveria reproduzir. **Calibrar** é ajustar os pesos o mínimo necessário para que a amostra reproduza totais conhecidos. A intuição: se a amostra tem 3.582 mulheres de 20 a 24 anos no urbano do Nordeste e o total conhecido é 274.407, o peso médio delas tem de ser 76,6; a calibração faz isso simultaneamente para todas as células, mexendo o menos possível em cada peso.

Há dois conjuntos de totais a que se pode calibrar, e eles servem a fins diferentes:

- **Os resultados preliminares de 1965** (Volume II) foram calculados com esta mesma amostra, antes do dano. Calibrar a eles repara o dano e devolve os pesos que o IBGE usou: a amostra volta a reproduzir a publicação de 1965 célula a célula. Mas não traz nenhuma informação de fora, e por isso não reduz o erro amostral (seção 13.5).
- **Os resultados definitivos** (Série Nacional, vol. I) são outra coisa: por unidade da federação, a população presente por sexo e grupos de idade, por situação e a alfabetização vêm da contagem completa em onze unidades da federação e da amostra de 25% nas outras dezessete (seção 3.3) — vinte vezes mais precisas que esta subamostra. Calibrar a elas ancora a amostra no que o censo contou, por unidade da federação e não só por região, e torna real a redução de variância.

Por isso há dois pesos. O final é o segundo; o primeiro fica nas tabelas para quem quiser reproduzir 1965 e para medir, contra o final, quanto os preliminares se afastam dos definitivos.

1.13.3 10.3 censobr_weight: calibrado aos resultados definitivos

As restrições são 543, todas sobre **peças presentes**, isto é, V202 fora de 3 e 4 (moradores ausentes). Elas vêm de três tabelas do volume nacional dos resultados definitivos, e valem descritas uma a uma, com a variável do arquivo de um lado e a página publicada do outro.

bloco	variável do arquivo	categorias	recorte	células	fonte
(a) sexo × idade	V202 para o sexo (1, 3, 5 = homens; 2, 4, 6 = mulheres) e V204/V204B para a idade	2 sexos × 11 faixas: 0-4, 5-9, 10-14, 15-19, 20-24, 25-29, 30-39, 40-49, 50-59, 60-69, 70 e mais	cada unidade da federação com oito pastas ou mais (21 delas), uma a uma	462	tabela 33, pp. 82-84
(b) total por sexo	V202	2 sexos, sem abrir a idade	as seis unidades pequenas — Rondônia, Acre, Roraima, Amapá, Fernando de Noronha, Serra dos Aimorés	12	tabela 33, coluna TOTAIS, p. 82
(c) população urbana	V118	quadro urbano (1) e suburbano (3) somados, contra o rural (5)	as mesmas 21 unidades com oito pastas ou mais	21	tabela 34, coluna “urbana”, p. 85
(d) sabem ler e escrever	V211	só a categoria “sabem” (códigos 0 e 1), entre os presentes de 5 anos e mais , por sexo	as 21 unidades uma a uma; as quatro pequenas do Norte e Centro-Oeste somadas num grupo; Noronha e Aimorés sozinhas	48	tabela 40, linha “sabem”, p. 98

Três detalhes de construção que mudam o resultado e que o código fixa. A **idade** é lida de V204, que diz em que unidade ela veio: meses (0) viram zero anos; anos (1) usam V204B; acima de 99 anos (5), ignorada (9) e ausente caem na última faixa. A última faixa é **“70 e mais e ignorada”** justamente por isso — ela soma as duas linhas que a tabela 33 publica separadas, porque o arquivo não distingue confiavelmente uma da outra. E só “sabem” entra como restrição em (d), não “não sabem”: os dois somam o total da faixa etária, que já está preso por (a), de modo que restringir os dois seria redundante e tornaria o sistema singular.

A tabela 33 é a maior das três e dá as margens (a) e (b). É esta página:

A linha 1 dessa página, “BRASIL ... 70 191 370”, é o total contra o qual a compilação inteira fecha; as linhas 2 a 34 são as regiões e as unidades da federação a que os pesos se calibram, uma a uma. A tabela 34 dá o corte urbano/rural da margem (c) e a tabela 40, a alfabetização da margem (d):

As três estão transcritas em `references/censo_1960_resultados_definitivos_serie_nacional.csv`, que guarda a página de cada célula na coluna `pagina`, e a transcrição é reproduzível por `references/transcricao_1960_serie_nacional.csv`. As margens são 543 contra as 184 do peso de 1965; as onze faixas são as de 1965, somando “70 e mais” e “idade ignorada” da tab. 33. O que fica fora, e por quê:

VII CENSO DE 1960											
33. GRUPOS DE IDADE, POR SEXO, SEGUNDO AS REGIÕES FISIOGRAFICAS E AS UNIDADES DA FEDERACAO											
NUN- DE- DEN	REGIÕES FISIOGRAFICAS	GRUPOS DE IDADE									
		TOTALIS					O A 4 ANOS				
		5 A 9 ANOS					10 A 14 ANOS				
		15 A 19 ANOS					20 A 24 ANOS				
UNIDADES DA FEDERACAO	TOTAL	HOMENS		MULHERES		HOMENS		MULHERES		HOMENS	
		MULHERES		HOMENS		MULHERES		HOMENS		MULHERES	
1	BRASIL.....	70 191 370	35 059 546	35 131 824	5 687 512	5 505 877	5 170 579	4 987 244			
2	NORTE.....	2 579 442	1 315 221	1 264 221	235 052	224 568	205 704	195 374			
3	PONTO GROSSO.....	70 232	39 036	31 194	6 977	6 216	5 575	5 059			
4	ACRE.....	158 852	84 208	74 644	15 328	14 729	13 701	12 816			
5	AMAZONAS.....	714 774	367 333	347 441	67 063	64 615	57 678	54 643			
6	PORANGA.....	28 871	15 018	13 853	2 965	2 931	2 571	2 516			
7	PARA.....	1 538 193	774 626	763 567	135 817	131 252	120 482	114 875			
8	ANAPA.....	68 520	34 998	33 522	6 882	6 765	5 697	5 465			
9	NORDESTE.....	15 486 240	7 568 238	7 918 002	1 286 131	1 257 206	1 169 437	1 147 394			
10	MARANHO.....	2 477 371	1 256 406	1 220 965	213 397	203 407	203 845	190 522			
11	PIAU.....	1 249 200	616 940	632 260	111 320	108 052	100 611	97 364			
12	CEARA.....	3 289 595	1 601 904	1 687 691	276 973	268 712	246 221	240 714			
13	RIO GRANDE DO NORTE.....	1 140 823	555 308	585 515	96 170	92 927	79 829	79 219			
14	PARAIBA.....	1 991 145	960 449	1 030 696	157 937	156 041	146 043	147 661			
15	PERNAMBUCO.....	4 080 601	1 966 907	2 113 694	327 132	325 288	296 585	296 190			
16	ALAGAS.....	1 256 159	609 590	646 569	103 056	102 635	96 209	95 655			
17	PERNAMBUCO DE NORONHA.....	1 346	734	612	146	144	94	69			
18	LESTE.....	24 570 761	12 180 026	12 390 735	1 996 881	1 932 903	1 817 875	1 753 052			
19	SERGIPE.....	751 778	361 338	390 440	64 557	62 458	58 822	57 247			
20	BAHIA.....	5 918 872	2 886 897	3 031 975	497 584	486 699	448 996	437 135			
21	MINAS GERAIS.....	9 698 118	4 846 200	4 851 918	820 523	794 360	748 236	718 798			
22	SERA DOS AIMOES.....	382 794	199 289	183 505	38 966	36 275	34 048	30 845			
23	ESPIRITO SANTO.....	1 169 553	594 423	575 130	106 864	102 504	95 567	91 654			
24	RIO DE JANEIRO.....	3 367 730	1 697 880	1 669 858	272 852	261 923	254 674	241 541			
25	GUANABARA.....	3 281 908	1 593 999	1 687 909	195 535	188 684	177 532	175 830			
26	SUL.....	24 605 438	12 459 937	12 145 501	1 913 852	1 845 683	1 744 337	1 671 569			
27	SÃO PAULO.....	12 823 806	6 477 519	6 346 287	934 478	902 313	846 467	815 507			
28	PARANA.....	4 263 721	2 211 922	2 051 799	373 196	357 327	335 452	316 401			
29	SANTA CATARINA.....	2 129 252	1 079 105	1 050 147	192 772	186 545	174 048	166 296			
30	RIO GRANDE DO SUL.....	5 388 659	2 691 391	2 697 268	413 406	399 498	386 370	373 185			
31	CENTRO-OESTE.....	2 949 489	1 536 124	1 413 365	255 596	243 517	233 226	220 435			
32	MATO GROSSO.....	892 233	465 382	426 851	78 303	73 891	70 865	66 049			
33	GOIAS.....	1 917 460	983 456	934 004	167 491	160 235	155 360	147 277			
34	DISTRITO FEDERAL.....	139 796	87 284	52 510	9 802	9 391	7 001	7 109			

Figura 8: Tabela 33 da Série Nacional, p. 82: população presente por sexo e grupos de idade, por unidade da federação

CENSO DEMOGRAFICO - BRASIL											
34. SITUAÇÃO DO DOMICÍLIO, POR SEXO, SEGUNDO AS REGIÕES FISIográfICAS E AS UNIDADES DA FEDERAÇÃO											
REGIÕES FISIográfICAS	SITUAÇÃO DO DOMICÍLIO										
	TOTAIS			POPULAÇÃO URBANA			POPULAÇÃO RURAL				
UNIDADES DA FEDERAÇÃO	TOTAL	HOMENS	MULHERES	TOTAL	HOMENS	MULHERES	TOTAL	HOMENS	MULHERES		
BRASIL.....	70 191 370	35 059 546	35 131 824	31 533 681	15 189 711	16 343 970	38 657 689	19 869 835	18 787 854		
NORTE.....	2 579 442	1 315 221	1 264 221	972 331	467 450	504 881	1 607 111	847 771	759 340		
ACRE.....	70 232	39 038	31 194	30 626	15 714	14 912	39 606	23 324	16 282		
ALAGOAS.....	158 852	84 208	74 644	33 534	16 445	17 089	125 318	67 763	57 555		
AMAZONAS.....	714 774	367 333	347 441	236 654	113 802	122 852	478 120	253 531	224 589		
BAHIA.....	28 871	15 018	13 853	12 460	6 282	6 178	16 411	8 736	7 675		
PARÁ.....	1 538 193	774 624	763 567	623 816	297 846	325 970	914 377	476 780	437 597		
PARANÁ.....	68 520	34 998	33 522	35 241	17 361	17 880	33 279	17 437	15 842		
PERNAMBUCO.....	15 486 240	7 568 238	7 918 002	5 212 546	2 410 026	2 802 522	10 273 692	5 158 212	5 115 480		
PIAUÍ.....	2 477 371	1 256 406	1 220 965	442 995	209 827	233 168	2 034 376	1 046 579	987 797		
CEARÁ.....	1 249 200	616 940	632 260	292 422	134 234	158 188	956 778	482 706	474 072		
RIO GRANDE DO NORTE.....	3 289 595	1 601 904	1 687 691	1 103 436	507 931	595 505	2 186 159	1 093 973	1 092 186		
PARANÁ.....	1 140 823	555 308	585 515	427 543	197 300	230 243	713 280	358 008	355 272		
PARANÁ.....	1 991 145	960 449	1 030 696	695 232	319 090	376 142	1 295 913	641 359	654 554		
PERNAMBUCO.....	4 080 601	1 966 907	2 113 694	1 828 426	847 040	981 386	2 252 175	1 119 867	1 132 308		
ALAGOAS.....	1 286 159	609 590	646 569	421 148	193 870	227 278	865 011	415 720	449 291		
FERNANDO DE NORONHA.....	1 346	734	612	1 346	734	612					
LESTE.....	24 570 761	12 180 026	12 390 735	11 877 084	5 693 975	6 183 709	12 693 677	6 486 651	6 207 026		
SERGIPE.....	751 778	361 338	390 440	291 109	132 830	158 279	460 669	228 508	232 161		
BAHIA.....	5 918 872	2 886 897	3 031 975	2 049 124	951 321	1 097 803	3 869 748	1 935 576	1 934 172		
MINAS GERAIS.....	9 698 118	4 844 200	4 854 918	3 880 388	1 851 569	2 028 819	5 817 730	2 994 631	2 823 099		
SERNA DOS JAMURES.....	382 794	199 289	183 505	33 757	16 637	17 120	349 037	182 652	166 385		
ESPIRITO SANTO.....	1 169 553	594 423	575 130	370 075	179 284	190 791	799 478	415 139	384 339		
RIO DE JANEIRO.....	3 367 738	1 687 880	1 649 858	2 054 040	1 011 618	1 042 422	1 313 698	686 262	627 436		
GOIABARA.....	3 281 908	1 593 999	1 687 909	3 198 591	1 550 110	1 648 475	83 317	43 883	39 434		
SUL.....	24 605 438	12 459 937	12 145 501	12 455 983	6 109 128	6 346 855	12 149 455	6 350 809	5 798 646		
SÃO PAULO.....	12 823 806	6 477 519	6 346 287	8 044 377	3 961 060	4 083 317	4 779 429	2 516 459	2 262 970		
PARANÁ.....	4 263 721	2 211 922	2 051 799	1 310 969	650 960	660 009	2 952 752	1 560 962	1 391 790		
SANTA CATARINA.....	2 129 252	1 079 105	1 050 147	688 358	337 305	351 053	1 440 894	741 800	699 094		
RIO GRANDE DO SUL.....	5 388 659	2 691 391	2 697 268	2 412 279	1 159 803	1 252 476	2 976 380	1 531 588	1 444 792		
CENTRO-OESTE.....	2 949 489	1 536 124	1 413 365	1 015 735	509 732	506 003	1 933 754	1 026 392	907 362		
MATO GROSSO.....	892 233	465 382	426 851	346 922	170 000	176 922	545 311	295 382	249 929		
GOIAS.....	1 917 460	983 456	934 004	580 518	279 649	300 869	1 336 942	703 807	633 135		
DISTRITO FEDERAL.....	139 796	87 286	52 510	88 293	40 083	48 210	51 501	27 203	24 298		

Figura 9: Tabela 34 da Série Nacional, p. 85: população presente por situação do domicílio

- **O Distrito Federal** não entra em nenhuma célula e fica no peso de desenho. O arquivo perdeu quatro quintos dos seus boletins, e o que falta é desproporcionalmente operário da construção (seção 4); forçar os 137 domicílios que restaram a representar 140 mil pessoas seria criar com peso o que o arquivo perdeu. O DF fica em 43 mil pessoas, 31% do publicado, com a composição do que sobreviveu; o total do Norte e Centro-Oeste, e o do país, ficam 97 mil pessoas abaixo do publicado por isso.
- **As faixas de idade das seis unidades pequenas.** Foi testado juntar as quatro do Norte e Centro-Oeste num “resto” com margens de idade, em onze e em cinco faixas: os fatores implícitos das quatro vão de 0,7 (Amapá) a 1,6 (Rondônia), e a estrutura etária conjunta só fechava inflando famílias grandes de Rondônia até 7 vezes. Elas ficam só com o total por sexo.
- **A cor.** Foi testada como restrição, por sexo e região, e rejeitada: no arquivo, quem ficou sem código de cor é dano — cinco vezes mais que o “sem declaração” publicado —, e essas pessoas fazem falta aos pretos e pardos; a calibração compensava inflando as famílias grandes com código válido. A cor fica como validação (10.7).
- **Os domicílios** (tab. 7) ficam como validação, pela regra de calibrar ao que é demográfico e medir o resto.
- **O corte urbano/rural nas unidades pequenas:** com uma ou duas pastas ele não tem como ser reproduzido (no Acre a pasta urbana precisaria de fator 0,23 e a rural de 6).

Dois cuidados a mais. Os fatores são mantidos entre 0,3 e 3,5 pela distância logit (10.5): o raking puro faz o fator crescer com o tamanho do domicílio, e nas unidades de uma pasta chegava a 9. E para Fernando de Noronha o peso de desenho usado é 4 (10.1), de modo que o seu fator em relação aos 78,74 nominais é 0,05 a 0,09 — o valor certo, não uma anomalia.

1.13.4 10.4 censobr_weight_1965: calibrado aos resultados preliminares

As restrições são as **176 células do quadro 1** — 4 regiões × 2 situações (urbana, que soma quadro urbano e suburbano, e rural) × 2 sexos × 11 faixas de idade, sempre população presente — e as **8 do quadro 2** que contam quem sabe ler e escrever, por sexo e região, entre os presentes de 5 anos e mais. São 184 restrições, reproduzidas exatamente, com o raking sem limites.

Os quadros são os **regionais**, não os do Brasil: o volume repete a mesma série de sete quadros para cada uma das quatro regiões que a amostra foi dimensionada para estimar (Nordeste, Leste, Sul e o par Norte e Centro-Oeste). O par que entra na calibração é este, aqui no bloco do Nordeste, às páginas 17 e 18:

17

RESULTADOS PRELIMINARES - REGIÃO NORDESTE

1. População urbana e rural, por sexo e grupos de idade

GRUPOS DE IDADE	TOTAIS			POPULAÇÃO URBANA			POPULAÇÃO RURAL		
	Total	Homens	Mulheres	Total	Homens	Mulheres	Total	Homens	Mulheres
TOTAIS	15 524 609	7 613 641	7 910 968	5 449 423	2 522 960	2 926 463	10 075 186	5 090 681	4 984 505
0 a 4 anos	2 564 359	1 319 349	1 245 010	852 429	435 102	417 327	1 711 930	884 247	827 683
5 a 9 anos	2 331 671	1 181 924	1 149 747	753 804	372 174	381 630	1 577 867	809 750	768 117
10 a 14 anos	2 012 131	997 956	1 014 175	680 428	320 215	360 213	1 331 703	677 741	653 962
15 a 19 anos	1 643 181	777 937	865 244	571 704	249 980	321 724	1 071 477	527 957	543 520
20 a 24 anos	1 353 308	611 730	741 578	492 445	206 223	286 222	860 863	405 507	455 356
25 a 29 anos	1 026 528	462 329	564 199	376 911	154 387	222 524	649 617	307 942	341 675
30 a 39 anos	1 748 454	828 889	919 565	663 389	296 903	366 486	1 085 065	531 986	553 079
40 a 49 anos	1 245 882	634 252	611 630	456 435	215 631	240 804	789 447	418 621	370 826
50 a 59 anos	798 248	401 178	397 070	296 282	136 291	159 991	501 966	264 887	237 079
60 a 69 anos	511 703	263 714	247 989	189 146	87 386	101 760	322 557	176 328	146 229
70 anos e mais e idade ignorada	289 144	134 383	154 761	116 450	48 668	67 782	172 694	85 715	86 979

Figura 11: Quadro 1 dos Resultados Preliminares de 1965, Nordeste, p. 17: população urbana e rural por sexo e grupos de idade

RESULTADOS PRELIMINARES - REGIÃO NORDESTE
2. Alfabetização, por sexo e grupos de idade

GRUPOS DE IDADE	PESSOAS PRESENTES, DE 5 ANOS E MAIS								
	Totais*			Sabem ler e escrever			Não sabem ler e escrever		
	Total	Homens	Mulheres	Total	Homens	Mulheres	Total	Homens	Mulheres
5 anos e mais ...	12 960 250	6 294 292	6 665 958	4 401 398	2 128 956	2 272 442	8 554 823	4 163 282	4 391 541
10 anos e mais ..	10 628 579	5 112 368	5 516 211	4 183 176	2 026 248	2 156 928	6 441 374	3 084 066	3 357 308
15 anos e mais ..	8 616 448	4 114 412	4 502 036	3 445 276	1 690 012	1 755 264	5 167 301	2 422 504	2 744 797
15 e 6 anos	991 194	507 927	483 267	20 619	10 349	10 270	970 575	497 578	472 997
7 a 12 anos	2 635 908	1 321 347	1 314 561	629 532	292 873	336 659	2 006 376	1 028 474	977 902
13 a 19 anos	2 359 881	1 128 543	1 231 338	1 042 528	450 786	591 742	1 317 195	677 599	639 596
20 a 24 anos	1 353 308	611 730	741 578	629 964	280 167	349 797	723 265	331 563	391 702
25 a 29 anos	1 026 528	462 329	564 199	456 752	210 070	246 682	569 776	252 259	317 517
30 a 39 anos	1 748 454	828 889	919 565	732 861	371 783	361 078	1 015 593	457 106	558 487
40 a 49 anos	1 245 882	634 252	611 630	426 565	239 805	186 760	819 238	394 368	424 870
50 a 59 anos	798 248	401 178	397 070	251 943	147 813	104 130	546 305	253 365	292 940
60 anos e mais e idade ignorada	800 847	398 097	402 750	210 634	125 310	85 324	586 500	270 970	315 530

* Inclusive as pessoas sem declaração de alfabetização.

Figura 12: Quadro 2 dos Resultados Preliminares de 1965, Nordeste, p. 18: alfabetização por sexo e grupos de idade

As faixas de idade do quadro 1 são as mesmas onze que o peso final usa (seção 10.3) — foi daqui que elas vieram. Do quadro 2 entra só a linha de quem **sabe** ler, pelo mesmo motivo de lá: o total da faixa já está preso pelo quadro 1, e restringir também quem não sabe tornaria o sistema singular. A transcrição dos sete quadros está em `references/censo_1960_resultados_preliminares_1965.csv`; ao contrário da transcrição dos definitivos, ela não guarda a página de cada célula. Duas ampliações foram testadas e rejeitadas: o estado conjugal (quadro 5) faz os pesos explodirem, porque força os domicílios que perderam o cartão do chefe a compensar com peso o que falta; o ramo de atividade (quadro 3) conserta o ramo à custa de inflar até 5,8 vezes os domicílios do Norte e Centro-Oeste com operários da construção — isto é, cria com peso os operários de Brasília que o arquivo perdeu.

1.13.5 10.5 Como se calibra

Pelo método de Deville e Särndal (1992). Para cada domicílio k da amostra s , seja $\mathbf{x}_k$ o vetor que conta quantas pessoas do domicílio caem em cada célula de restrição, e $\mathbf{T}$ o vetor dos totais publicados. O peso calibrado é

$$w_k = w_k^d g(\mathbf{x}_k^\top \lambda), \quad \text{com } \lambda \text{ tal que } \sum_{k \in s} w_k \mathbf{x}_k = \mathbf{T}.$$

Com a distância “raking”, $g(u) = e^u$, que é o que o peso de 1965 usa. Com a distância logit, usada no peso final, o fator fica entre limites $L = 0,3$ e $U = 3,5$:

$$g(u) = \frac{L(U-1) + U(1-L)e^{Au}}{(U-1) + (1-L)e^{Au}}, \quad A = \frac{U-L}{(1-L)(U-1)},$$

que vale 1 em $u = 0$ e tende a L e a U nos extremos. Nos dois casos λ é resolvido por Newton (com meio passo quando o desvio não cai). O peso é **um por domicílio**, o mesmo para todas as suas pessoas (peso integrado): isso garante que pessoas e domicílios sejam estimados com os mesmos pesos, e que um domicílio nunca “represente” 80 chefes e 90 cônjuges. O preço do peso integrado é que o fator de um domicílio é g da soma dos λ das suas pessoas: numa célula que precisa subir 30%, uma família de dez sobe muito mais que uma de dois — é o que os limites da distância logit contêm.

1.13.6 10.6 O resultado

`censobr_weight` vai de 3,8 (Noronha) a 275, com 98% dos domicílios entre 53,8 e 109 e mediana 78,6:

Os pesos calibrados ficam perto do peso de desenho

98% dos domicílios entre 53,8 e 109; o eixo está cortado em 160 (máximo 275,3).




Figura 13: A distribuição do peso calibrado dos domicílios em torno do peso de desenho

O fator `censobr_weight_fator` tem percentis 1 e 99 em 0,68 e 1,38; a mediana por unidade da federação fica entre 0,86 (Sergipe) e 1,10 (Mato Grosso) nas unidades com oito pastas ou mais, e vai a 0,51 (Amapá), 0,57 (Acre) e 0,72 (Roraima) nas pequenas, que o desenho havia sobre-representado. Nos limites de 0,3 e 3,5 ficam 252 domicílios, quase todos nas pequenas. Para comparação, `censobr_weight_1965` vai de 38,6 a 384,5, com 98% entre 72,8 e 89,6 e fator de 0,49 a 4,88.

1.13.7 10.7 O que cada peso reproduz, e o que não

Com `censobr_weight`, as células restritas dos resultados definitivos fecham por construção. O que informa são as células que não foram restrição (`calibracao_definitivos_validacao.csv`): os domicílios particulares e os seus moradores por unidade da federação e situação (tab. 7) ficam a 2,4% do publicado na mediana — 1,8% nas unidades com oito pastas ou mais, 4,7% no percentil 90; os pretos e pardos por unidade da federação (tab. 37) ficam dentro de $\pm 15\%$ nas grandes (Bahia -5% e $+5\%$, Minas $+6\%$ e $+4\%$, São Paulo -8% e -14% , Pernambuco $+9\%$ e $+15\%$, Guanabara -2% e -7%); a população rural das unidades pequenas não é reproduzida (Acre $+109\%$ no urbano e -29% no rural); Noronha reproduz os presentes exatamente e passa 41% nos residentes; o DF fica em 31% do publicado.

Contra os quadros de 1965 (`calibracao_1965_validacao.csv`), `censobr_weight_1965` reproduz os quadros 1 e 2 exatamente e os demais dentro de 1% a 2% na mediana. `censobr_weight` reproduz o quadro 1 a 2% na mediana e a 23% no pior caso — o urbano do Norte e Centro-Oeste, -12% , onde se somam o DF no peso de desenho (-97 mil) e a diferença entre a tabulação preliminar de 1965 e a definitiva, que é o erro amostral desta mesma amostra —, e os quadros 3 a 7 a 2% a 3,5% na mediana. Essa distância entre os dois pesos é a medida do que a calibração aos definitivos corrige: a estimativa de 1965 carregava, além do dano posterior, o próprio erro amostral da subamostra.

1.13.8 10.8 O que o peso não faz

Nenhum peso cria o que não foi amostrado. Rondônia só tem Porto Velho urbano; o Amapá tem uma pasta; o Acre, duas; Fernando de Noronha só tem urbano; o Distrito Federal perdeu dois terços dos seus boletins e ficou no peso de

desenho. Para essas unidades, a estimativa descreve o que foi sorteado e sobreviveu, no tamanho que os totais por sexo impõem, e nada mais.

1.14 11. As colunas de desenho nas tabelas

Duas colunas, presentes nas tabelas de pessoas e de domicílios, dizem como o sorteio foi feito:

- **censobr_upa** — a **unidade primária de amostragem**: a pasta, identificada por unidade da federação e número (815 valores). O número da pasta, sozinho, está em **pasta**.
- **censobr_estrato** — o **estrato**: a unidade da federação cruzada com o grupo de situação da pasta, como a Parte II demonstrou. São **75 estratos**, dos quais 64 são de uma unidade da federação só (rótulo UF 60 - cidade grande, por exemplo) e 11 juntam duas ou três unidades vizinhas (rótulo UF 10+12 - cidade grande), pela regra de colapso explicada abaixo. Cada estrato tem de 2 a 54 pastas, mediana 7; o único com uma pasta só é Fernando de Noronha, e é de propósito (adiante).

Como cada pasta foi classificada. Pela situação dos seus próprios boletins: mista se tem urbanos e rurais; rural se só tem rurais; e as puramente urbanas se dividem pelo tamanho do município — cidade grande é a pasta puramente urbana de município com população urbana de 100 mil ou mais no Anuário de 1961, casada pelo código de município (`read_guides/1960_municipios.csv`); urbana menor são as demais. É a regra que a seção 8 mostrou reproduzir melhor o sorteio. Nas 11 unidades da federação em que a amostra de 25% não sobreviveu, a regra é a mesma, mas sem a verificação que o cadastro permite.

A regra de colapso. Um estrato com uma pasta só não permite medir variância: não há com o que comparar. Onde isso acontece, a unidade da federação solitária naquele grupo de situação se junta à **primeira vizinha da mesma região que tenha pasta no mesmo grupo**, e só a ela; a lista de vizinhas, por adjacência em 1960 e em ordem de preferência, está em `VIZINHAS_1960 (R/microdata_1960_amostra_127.R)`. O processo se repete até nenhum estrato ficar com uma pasta. São onze juntas, que reúnem 54 das 815 pastas:

estrato	pastas	quem se juntou
Sergipe + Bahia, cidade grande	9	Sergipe tinha só Aracaju
Serra dos Aimorés + Espírito Santo, urbana menor	3	Aimorés tinha uma pasta
Rio de Janeiro + Guanabara, rural	7	a Guanabara tinha uma pasta rural
Maranhão + Piauí, cidade grande	2	São Luís e Teresina, uma pasta cada
Maranhão + Piauí, urbana menor	2	uma pasta cada
Rio Grande do Norte + Paraíba, urbana menor	4	o Rio Grande do Norte tinha uma
Amazonas + Pará + Goiás, cidade grande	6	Amazonas e Goiás, uma pasta cada
Rondônia + Acre + Mato Grosso, urbana menor	4	uma pasta cada em Rondônia e no Acre
Pará + Goiás, urbana menor	4	o Pará tinha uma
Acre + Amazonas, mista	5	o Acre tinha uma
Pará + Amapá, mista	8	o Amapá tinha uma

A regra anterior dissolvia o grupo de situação inteiro da região — oito estratos que reuniam 266 das 815 pastas —, o que era mais grosso que o desenho e **umentava** o erro-padrão estimado sem necessidade. Juntar só a vizinha corrige isso: o erro-padrão da população presente do Norte e Centro-Oeste cai de 224.277 para 161.705 (−28%), o do Leste de 338.852 para 305.795 (−10%), e o rural do Brasil de 606.536 para 581.246 (−4%); no Sul, onde não houve colapso, nada muda. A seção 13.3 traz a comparação completa.

Fernando de Noronha é um estrato de certeza. A sua única pasta era o cadastro inteiro (seção 6.2): não houve sorteio de pasta ali, e por isso o estrato fica sozinho de propósito e a etapa das pastas não contribui variância nenhuma. No survey isso se escreve com $fpc = 1$ para a unidade da federação 24; o passo 11 faz o mesmo.

As regiões são as do Volume II: Nordeste (MA, PI, CE, RN, PB, PE, FN, AL), Leste (SE, BA, MG, Serra dos Aimorés, ES, RJ, GB), Sul (SP, PR, SC, RS) e Norte e Centro-Oeste (RO, AC, AM, RR, PA, AP, MT, GO, DF).

Por que isso basta para o erro-padrão. Para estimar variância de uma amostra de conglomerados é preciso saber (a) quais observações foram sorteadas juntas — a pasta — e (b) dentro de que grupos o sorteio foi independente — o estrato. Errar o estrato para mais grosso (juntar estratos que o IBGE separava) superestima a variância, porque atribui ao acaso diferenças que na verdade estavam controladas pela estratificação. Errar para mais fino subestima. As colunas dão o desenho demonstrado, e onde há dúvida o erro é para o lado grosso.

A pasta é a unidade primária, e o domicílio é a etapa anterior — que a tabela publicada escreve como segunda etapa. Vale desfazer aqui uma confusão que a ordem cronológica provoca. No desenho de livro-texto, sorteiam-se conglomerados e depois unidades dentro deles. Aqui a ordem é a inversa: o domicílio foi sorteado **primeiro**, no campo, um em cada quatro na Folha de Coleta; as pastas foram formadas **depois**, no órgão central, com os boletins que já estavam na amostra; e o sorteio de uma pasta em vinte veio por último. Dentro de uma pasta sorteada **não há subamostragem**: todos os seus boletins entram.

Para a variância, o que importa não é a cronologia e sim qual unidade a amostra entrega em bloco, e essa é a pasta. Por isso a pasta é a unidade primária: é o conglomerado último, e é a dispersão entre pastas que carrega a dependência entre os domicílios de uma mesma pasta. Pôr o domicílio como primeira etapa seria tratá-lo como sorteado por si, e o erro-padrão sairia muito menor que o verdadeiro.

O que muda na tabela que o censobr publica é a **escrita**, não o desenho. Lá o par de etapas aparece explicitamente, porque é assim que o survey o aceita numa chamada só: `censobr_upa` é a pasta com $fpc = 1/20$ na primeira etapa, e `censobr_usa` é o domicílio com $fpc2 = 1/4$ na segunda. O estimador que sai disso é exatamente o desta seção — o termo entre pastas, mais a parcela da etapa dos domicílios que a seção 13.2 mede e mostra valer de 0,05% a 1,2% da variância. Escrever as duas etapas não acrescenta nada à conta; dispensa o usuário de fazê-la à mão. A seção 14 mostra a chamada.

Neste estágio, que é anterior à compilação, as tabelas trazem só `censobr_upa` e `censobr_estrato`; `censobr_usa` e `censobr_fpc2` nascem na compilação, onde o domicílio passa a ter identificador único no país.

(A compilação de 2019/2024 do censobr trazia colunas `censobr_upa` e `censobr_usa` com outra convenção: nos registros da amostra de 25% a unidade primária era o próprio domicílio, e nos de 1,27% era o município. Nenhuma das duas corresponde ao desenho descrito aqui, e as duas foram substituídas.)

1.15 12. Como calcular o erro-padrão, e o que ele diz

1.15.1 12.1 Por que não tratar as 897 mil linhas como 897 mil sorteios

As pessoas de uma pasta são vizinhas: mesmos setores, mesmo bairro ou mesma zona rural, mesma situação. Se a pasta sorteada é um bairro operário, ela traz 1.100 pessoas parecidas; a próxima pasta, vinte posições adiante no cadastro, pode ser outro mundo. A informação que a amostra contém sobre o país é, em boa medida, a informação de 817 pastas, não de 897 mil pessoas. Quem calcula o erro-padrão como se fossem sorteios independentes publica intervalos de confiança várias vezes estreitos demais — a seção 12.4 mostra quantas.

1.15.2 12.2 O estimador

Seja y_k a variável de interesse na pessoa k e w_k o seu peso calibrado. O total estimado e o total de cada pasta i do estrato h são

$$\hat{Y} = \sum_{k \in s} w_k y_k, \quad t_{hi} = \sum_{k \in (h,i)} w_k y_k.$$

A variância estimada tem duas parcelas. A primeira, que responde por quase tudo, é a dispersão dos totais das pastas dentro de cada estrato, somada sobre os $H = 75$ estratos, com a correção de população finita da etapa que sorteou as pastas:

$$\widehat{V}_{\text{entre}} = \sum_{h=1}^H (1 - f_h) \frac{n_h}{n_h - 1} \sum_{i=1}^{n_h} (t_{hi} - \bar{t}_h)^2, \quad \bar{t}_h = \frac{1}{n_h} \sum_{i=1}^{n_h} t_{hi},$$

onde n_h é o número de pastas sorteadas no estrato h e $f_h = 1/20$ é a fração sorteada (em Fernando de Noronha $f_h = 1$, e a parcela é zero: a única pasta era o cadastro inteiro). Isto é o estimador de **conglomerado último** (*ultimate cluster*): a variância vem da dispersão entre pastas dentro de cada estrato, como se elas tivessem sido sorteadas com reposição, e o fator $(1 - 1/20) = 0,95$ desconta a fração que o sorteio de uma em vinte tomou (a seção 13.2 justifica a correção). Dois detalhes: as pastas que não têm ninguém do domínio estimado entram com total zero, e é por isso que n_h é o número de pastas do estrato na amostra toda, e não só das que têm o domínio; e a calibração é ignorada aqui, o que para `censobr_weight` é conservador (seção 13.5).

A segunda parcela é a parte da etapa anterior — um domicílio em quatro, no campo — que a dispersão entre pastas não alcança. Somando sobre as pastas sorteadas, com m_i domicílios na pasta i e $u_k = w_k y_k$ o total ponderado do domicílio k :

$$\widehat{V}_{\text{dentro}} = \sum_{i \in s} f_i \left(1 - \frac{1}{4}\right) \frac{m_i}{m_i - 1} \sum_{k \in i} (u_k - \bar{u}_i)^2, \quad \widehat{V}(\hat{Y}) = \widehat{V}_{\text{entre}} + \widehat{V}_{\text{dentro}}.$$

O erro-padrão é a raiz da soma. A segunda parcela vale entre 0,04% e 0,06% do erro-padrão nos domínios grandes e até 1,2% da variância nas células pequenas: entra porque custa três linhas e fecha a conta, não porque mude alguma conclusão (seção 13.2).

O passo 11 do pipeline faz essa conta à mão, para que o cálculo não dependa de pacote externo. Que ela está certa se verifica com o `survey`, que está no `renv` do projeto: `svydesign(ids = ~censobr_upa, strata = ~censobr_estrato, weights = ~censobr_weight, fpc = ~fpc)`, com `fpc` igual a $1/20$ (e 1 em Fernando de Noronha), seguido de `svytotal`, devolve a primeira parcela até o último dígito — 305.795 no Leste, 263.437 no Nordeste, 161.705 no Norte e Centro-Oeste, 336.895 no Sul. O script da conferência é `references/conferencia_desenho_amostrai_1960.R`, que também refaz a segunda parcela e a variância pelos resíduos da calibração.

1.15.3 12.3 O efeito de desenho

É a razão entre a variância assim calculada e a que uma amostra aleatória simples de pessoas do mesmo tamanho teria:

$$\text{deff} = \frac{\widehat{V}(\hat{Y})}{\widehat{V}_{\text{AAS}}(\hat{Y})}, \quad \widehat{V}_{\text{AAS}}(\hat{Y}) = N^2 \left(1 - \frac{n}{N}\right) \frac{p(1-p)}{n-1}, \quad p = \hat{Y}/N,$$

com n o número de pessoas presentes na amostra e N a soma dos seus pesos. Ele diz “quantas vezes menos precisa” a amostra é do que parece. Um efeito de desenho 10 numa célula com 4.810 pessoas significa que ela vale o que valeriam 481 sorteios independentes. Para o total do país ele não existe, porque uma amostra calibrada a esse total o reproduz sem erro por construção.

1.15.4 12.4 O que os números dizem

Para a população presente:

A tabela traz as duas colunas que o passo 11 calcula: o erro-padrão **de desenho**, que ignora a calibração, e o erro-padrão **pelos resíduos da calibração**, que a leva em conta e só é legítimo para `censobr_weight`, cujos totais são externos (seção 13.5).

domínio	estimativa	erro-padrão	CV	efeito de desenho	pelos resíduos	CV
Brasil	70.094.960	537.588	0,77%	—	5.618	0,01%
Brasil, urbana	31.572.374	468.127	1,48%	162	53.292	0,17%
Brasil, rural	38.522.586	581.462	1,51%	249	52.995	0,14%
Leste	24.570.761	295.420	1,20%	70	0	0,00%
Sul	24.605.438	325.690	1,32%	85	0	0,00%
Nordeste	15.486.240	263.581	1,70%	74	0	0,00%
Norte e Centro-Oeste	5.432.521	161.800	2,98%	67	5.618	0,10%
Sul, urbana	12.455.833	260.482	2,09%	85	149	0,00%
Leste, urbana	11.901.020	306.836	2,58%	122	42.295	0,36%
Leste, rural	12.669.741	323.409	2,55%	129	42.295	0,33%
Sul, rural	12.149.605	345.607	2,84%	152	149	0,00%
Nordeste, rural	10.273.692	267.257	2,60%	104	0	0,00%
Nordeste, urbana	5.212.548	171.086	3,28%	78	0	0,00%
Norte e Centro-Oeste, rural	3.429.547	206.482	6,02%	167	31.932	0,93%
Norte e Centro-Oeste, urbana	2.002.973	166.954	8,34%	183	32.422	1,62%

Três leituras. **Os zeros da última coluna são legítimos**, e dizem o que a calibração garante: a população presente de cada região (fora o Distrito Federal) é a soma de células que foram restrição, e o peso a reproduz por construção. Os que não são zero dizem onde a garantia não chega: o Distrito Federal, que ficou no peso de desenho e responde sozinho pelos 5.618 do total do país e pelos 5.618 do Norte e Centro-Oeste; e o **corte urbano/rural**, que só foi restrição nas unidades da federação com oito pastas ou mais (seção 10.3) — daí os 42 mil do Leste e os 32 mil do Norte e Centro-Oeste. **O efeito de desenho continua alto** nos domínios definidos pela situação e pela região, porque essas são características da pasta inteira: estimar quanta gente mora no urbano do Nordeste é contar quantas pastas urbanas foram sorteadas ali e o tamanho de cada uma, e isso varia de sorteio para sorteio muito mais do que a contagem de pessoas sugere. **E o total do país tem erro-padrão**, ao contrário do que o peso de 1965 permitia: 550 mil pelo estimador de desenho, 5,6 mil pelos resíduos — a diferença entre ler a amostra como se a calibração não existisse e reconhecer que 543 totais externos a prendem.

Nas 176 células do quadro 1 (região × situação × sexo × idade), onde a variável de interesse varia dentro das pastas, o efeito de desenho tem mediana 5,9 (quartis 4,1 e 9,3, máximo 23,5) e o coeficiente de variação mediana 3,5%, máximo 11,8%; pelos resíduos da calibração o coeficiente de variação cai para mediana 1,3% e máximo 5,7%, ou 35% do erro-padrão de desenho na mediana:

Duas coisas sobre como ler essa figura. As três retas pontilhadas **não são tendências ajustadas aos pontos**: são referências de efeito de desenho constante. Com os dois eixos em escala logarítmica, elas são $y = x$, $y = 2x$ e $y = 4x$, e como o efeito de desenho é o quadrado da razão entre os dois coeficientes de variação, isso são as linhas de deff 1, 4 e 16. Um ponto sobre a segunda reta é uma célula cujo erro real é o dobro do que uma amostra aleatória simples daria. E o eixo horizontal é **derivado** do vertical: ele é o coeficiente de variação observado dividido pela raiz do efeito de desenho, de modo que a figura mostra a distribuição do efeito de desenho num outro sistema de coordenadas, e não o confronto de duas medidas independentes. Ela serve para ver onde estão as células, não para validar o cálculo.

O efeito de desenho cai com a idade — mediana 11,7 na faixa de 0 a 4 anos, 9,5 de 10 a 14, 6,1 de 20 a 24, 4,1 de 50 a 59, 2,9 de 60 a 69, 2,7 de 70 e mais —, porque famílias grandes e jovens se concentram em pastas (bairros e zonas rurais inteiros são jovens ou velhos), enquanto os idosos se espalham. Um exemplo completo, mulheres do urbano do Nordeste:

As 176 células do quadro 1: o erro real é 2 a 4 vezes o de uma amostra aleatória simples

As retas pontilhadas são referências de efeito de desenho constante, não tendências ajustadas. O eixo horizontal é derivado do ver




Figura 14: As 176 células do quadro 1: erro do desenho contra erro de uma amostra aleatória simples

faixa de idade	estimativa	erro-padrão	CV	efeito de desenho	peças na amostra	pelos resíduos	CV
0 a 4	406.124	17.355	4,3%	9,5	5.294	6.146	1,5%
5 a 9	364.611	15.464	4,2%	8,4	4.810	5.589	1,5%
20 a 24	274.407	9.944	3,6%	4,6	3.582	4.353	1,6%
40 a 49	235.509	8.583	3,6%	4,0	3.039	3.804	1,6%
60 a 69	99.011	5.942	6,0%	4,6	1.277	3.295	3,3%
70 e mais	67.133	4.199	6,3%	3,4	837	2.604	3,9%

Uma célula dessas, que com 4.810 pessoas pareceria ter um erro relativo de 1,4% se fosse aleatória simples, tem 4,2% pelo estimador de desenho e 1,5% quando se reconhece que a calibração prendeu o total da sua faixa etária na sua unidade da federação. O primeiro é o número honesto para quem trata o peso como dado; o segundo é o número honesto para quem sabe de onde ele veio. **Nas células que foram restrição, a segunda coluna é zero e a primeira não** — não porque uma esteja errada, mas porque respondem a perguntas diferentes (seção 13.5).

A tabela completa, com 191 domínios por peso, está em `data_raw/microdata/1960/amostra_127/erros_amostrais.csv`: coluna peso, mais `erro_padrao/cv_pct/deff` (desenho) e `erro_padrao_calibrado/cv_calibrado_pct` (resíduos, vazias para `censobr_weight_1965`).

1.16 13. As alternativas de cálculo, uma a uma

Esta seção percorre cada forma de calcular o erro-padrão que foi considerada, com a intuição, um exemplo numérico calculado neste arquivo e o que cada uma exige. Nada aqui muda os pesos nem os estratos das tabelas; muda o que se faz com eles. Cinco totais servem de exemplo ao longo da seção, todos para a população presente:

total (pessoas)	estimativa	pastas com o atributo	CV	efeito de desenho
operários da construção civil (classe 351)	726.540	657	3,6%	12
pessoas com rendimento acima de Cr\$ 10 mil	2.511.635	748	3,1%	31
analfabetos de 15 anos e mais	16.014.475	815	1,3%	43
solteiros de 15 anos e mais	13.439.199	814	1,0%	21
população urbana do Nordeste	5.212.548	106	3,3%	78

E o resumo, em milhares de pessoas, dos erros-padrão que cada alternativa dá; as subseções explicam cada coluna:

total	adotado (75 estratos, com correção finita)	sem correção finita	colapso no grupo da região (47)	estratos região × situação (16)	diferenças sucessivas	resíduos da calibração	se fosse aleatória simples
construção civil	26	27	27	27	25	24	7
rendimento > 10 mil	77	79	77	82	65	61	14
analfabetos 15+	204	210	205	215	200	33	31
solteiros 15+	134	138	134	140	130	47	29
urbana do Nordeste	171	175	186	190	173	0	19

O jackknife não tem coluna aqui, e a razão é que ele não teria números próprios: para um **total**, o jackknife de deleção de uma unidade primária é algebricamente idêntico ao estimador de conglomerado último (seção 13.6). Ele reapareceria como cópia da primeira coluna, com a correção finita, ou da segunda, sem ela.


A última coluna é o erro-padrão que uma amostra aleatória simples de pessoas do mesmo tamanho teria; a razão entre ela e a primeira, ao quadrado, é o efeito de desenho. É a medida do que a amostragem por pastas custa.

1.16.1 13.1 O ponto de partida: o que o estimador adotado supõe

O estimador da seção 12.2 trata a amostra como se, em cada um dos 75 estratos, as pastas tivessem sido sorteadas **independentemente umas das outras**, e como se os pesos fossem fixos. Nenhuma das duas coisas é exatamente verdade: as pastas foram sorteadas sistematicamente num cadastro ordenado (o que é melhor que independente), e os pesos foram calibrados (o que os torna dependentes da amostra). As duas simplificações erram para o lado seguro, isto é, produzem erros-padrão maiores que os verdadeiros. As alternativas abaixo relaxam uma simplificação de cada vez.

Uma imagem para fixar. Pense no cadastro de uma unidade da federação como uma fila de pastas, e nos grupos de situação como cores:

1 = conglomerado último com correção finita e 75 estratos (o adotado). Barras abaixo de 1 são erros menores.



cadastro (uma UF)	U U U U U U U U U U U U U U U U U U	M M M M M M M M	R R R R R R R R R R
número da pasta	02 04 06 08 10 12 14 16 18 20 22 24 ...	...	...
sorteio (uma em 20)	^	^	^

U, M e R são as pastas urbanas, mistas e rurais; cada grupo é uma sequência própria (é o que a Parte II demonstrou), e em cada sequência sorteia-se uma pasta a cada vinte. O estimador adotado olha para as pastas sorteadas de um estrato e mede o quanto os seus totais diferem entre si; quanto mais diferem, maior o erro-padrão.

1.16.2 13.2 A correção de população finita: adotada, e por quê

A ideia. Se uma amostra tomasse todas as pastas do cadastro, não haveria erro amostral nenhum. Tomando uma fração f delas, a variância de um total é proporcional a $(1 - f)$: sortear 5% das pastas deixa 95% do “espaço” para variar. A correção multiplica a variância por $(1 - 1/20) = 0,95$ e o erro-padrão por 0,975.

A dúvida. A amostra tem duas etapas, e — como a seção 11 explica — elas estão em ordem invertida: primeiro o domicílio (um em quatro, no campo), depois a pasta (uma em vinte, no escritório). Para a variância a ordem cronológica não importa, e vale a decomposição clássica da amostragem em duas etapas:

$$V(\hat{Y}) = V_{\text{pastas}} + V_{\text{dom}}, \quad V_{\text{dom}} = \frac{N_h}{n_h} \sum_{j=1}^{N_h} V_{2j},$$

onde V_{pastas} é a variância entre os totais verdadeiros das pastas, V_{2j} é a variância que o sorteio de um domicílio em quatro produz no total estimado da pasta j , e a soma percorre todas as N_h pastas do cadastro. A pergunta era o que o estimador da seção 12.2 faz com V_{dom} . A resposta, também clássica, é que o estimador entre pastas **já contém** $(1 - 1/20)$ de V_{dom} : cada total de pasta t_{hi} carrega o ruído da etapa dos domicílios, e a dispersão entre pastas o absorve. O que fica de fora é só a fração $1/20$ — a mesma fração que a correção finita desconta. A dúvida era se valia a pena descontar 5% de V_{pastas} deixando de fora $V_{\text{dom}}/20$.

A medida. V_{dom} se estima com a própria amostra, sem nenhuma informação externa, porque dentro de cada pasta o sorteio de um em quatro é, para todos os efeitos, aleatório simples com fração $1/4$ (é o que os “vários processos” de variação das linhas de amostra garantem), de modo que o cadastro da pasta tinha $4n_i$ domicílios. Com $u_k = w_k y_k / 20$ o total do domicílio k na escala da amostra de 25%,

$$\widehat{V}_{2i} = \left(1 - \frac{1}{4}\right) \frac{n_i}{n_i - 1} \sum_{k \in i} (u_k - \bar{u}_i)^2, \quad \widehat{V}_{\text{dom}} = 20^2 \sum_{i \in s} \widehat{V}_{2i}, \quad \text{parte que falta} = \frac{1}{20} \widehat{V}_{\text{dom}} = 20 \sum_{i \in s} \widehat{V}_{2i},$$

o que, em termos dos totais ponderados dos domicílios $w_k y_k$, dá a parte que falta igual a $f_h(1 - \text{frac14}) = 0,0375$ vezes a soma, sobre as pastas sorteadas, da soma de quadrados dos totais dos domicílios em torno da média da pasta — três linhas de código sobre a tabela de domicílios. Em Fernando de Noronha, onde $f_h = 1$ porque a pasta era o cadastro inteiro, o fator é 0,75: ali a etapa dos domicílios não é resíduo, é **toda** a variância — o que resta de aleatório em Noronha é o sorteio de um domicílio em quatro, e a seção 10.1 mostra que a pasta de 1,27% contém de fato os 62 dos 75 domicílios da amostra de 25% que sobreviveram. Medida nos cinco totais-exemplo e em duas células:

total	V_{dom} como fração da variância	parte que falta ($V_{\text{dom}}/20$)	aumento do erro-padrão se incluída
operários da construção civil	7,2%	0,36%	+0,18%
rendimento acima de Cr\$ 10 mil	2,0%	0,10%	+0,05%
analfabetos de 15 anos e mais	2,8%	0,14%	+0,07%
solteiros de 15 anos e mais	8,2%	0,41%	+0,21%
população urbana do Nordeste	2,2%	0,11%	+0,06%
mulheres de 20 a 24 anos, urbano do Nordeste	15%	0,75%	+0,37%
mulheres de 70 anos e mais, urbano do Nordeste	24%	1,19%	+0,60%

A etapa dos domicílios pesa de 2% a 24% da variância — mais nas células pequenas e nos idosos, que se espalham entre os domicílios —, mas 95% disso o estimador já mede. A parte que falta vale entre 0,1% e 1,2% da variância, ou seja, entre 0,05% e 0,6% do erro-padrão, contra os 5% da variância que a correção finita desconta. Não há compensação: omitir a correção seria inflar o erro-padrão em 2,5% para compensar uma omissão de 0,3%.

A decisão. A correção entra, com $f = 1/20$ em todos os estratos menos Fernando de Noronha, onde $f = 1$ e a etapa das pastas não tem variância (seção 11). O valor nominal da fração é o do desenho declarado, e o cadastro reconstruído o confirma (razão cadastro/sorteadas 19,9, quartis 19,1 e 21,3). **E a parte que falta de V_{dom} também entra**, desde 2026-09-15: são três linhas no passo 11, não exigem nenhuma informação externa, e fecham a conta. Medida nos totais regionais da população presente, ela acrescenta 0,04% ao erro-padrão do Sul, 0,05% ao do Nordeste e 0,06% ao do Leste e ao do Norte e Centro-Oeste — dentro do previsto pela tabela acima, e sem mudar nenhuma conclusão. Nas células pequenas e nos idosos, onde V_{dom} chega a um quarto da variância, o acréscimo chega a 0,6%.

1.16.3 13.3 A estratificação: por que unidade da federação × situação, e o que a alternativa mais grossa daria

A intuição. O estrato diz de que grupo de pastas a variação “conta”. Se o estrato fosse região × situação, duas pastas urbanas menores do Ceará e do Maranhão estariam no mesmo estrato, e a diferença entre elas — que é, em boa parte, a diferença entre Ceará e Maranhão — entraria no erro-padrão. Mas essa diferença não existia no sorteio: cada unidade da federação teve a sua própria série sistemática, com o seu próprio início (seção 7). Atribuí-la ao acaso é inflar a variância.

As alternativas, medidas. Há três graus de finura possíveis, e vale medir os dois que não foram adotados. O mais grosso é **região × situação**: 16 estratos, nenhum com pasta sozinha, a escolha prudente de quem não conhecesse o critério geográfico. O intermediário é a **regra de colapso anterior**, que usava a unidade da federação mas, onde ela ficava com uma pasta só num grupo, dissolvia o grupo inteiro da região — 47 estratos, dos quais oito reuniam 266 das 817 pastas. O adotado é o colapso fino da seção 11: 75 estratos, em que a unidade solitária se junta a **uma** vizinha. Recalculando os erros-padrão da população presente, tudo o mais igual:

domínio	região × situação (16)	colapso no grupo da região (47)	adotado, colapso na vizinha (75)
Norte e Centro-Oeste, total	224.277	224.277	161.705
Leste, total	338.852	338.852	305.795
Nordeste, total	272.744	272.744	263.437
Sul, total	337.164	336.895	336.895
Brasil, urbana	494.024	494.024	482.523
Brasil, rural	606.536	606.536	581.246

Nos totais regionais as duas primeiras colunas coincidem, e não é coincidência: a região e a situação são atributos da pasta inteira, de modo que nesses domínios a regra antiga se comportava exatamente como a mais grossa de todas. O ganho do colapso fino é grande justamente ali — 28% no Norte e Centro-Oeste, 10% no Leste — e nulo no Sul, onde nenhuma unidade da federação ficou sozinha. Nos cinco totais-exemplo, onde a variável de interesse varia dentro da pasta, a diferença é menor mas tem o mesmo sinal (figura 10): 186 mil contra 171 mil na população urbana do Nordeste, 215 mil contra 205 mil nos analfabetos.

O que se ganha é precisão sem custo de viés: cada junta reúne pastas que o IBGE sorteou separadamente, mas de unidades vizinhas e do mesmo grupo de situação, o que é a aproximação mais próxima possível do desenho real quando não há como medir dentro de uma unidade sozinha. Onde o erro-padrão **sobe** com estratos mais finos — acontece em alguns domínios pequenos — não é um erro: o estimador de variância é ele próprio uma variável aleatória, e estratos mais finos têm menos graus de liberdade, o que o torna mais instável. A justificativa da escolha não é o ganho; é a correspondência com o desenho real, demonstrada na Parte II.

1.16.4 13.4 Usar a ordem do cadastro: o estimador de diferenças sucessivas (opção)

A ideia. Numa amostra sistemática sobre uma lista ordenada, as pastas sorteadas vêm em ordem: a primeira da zona A, depois outra da zona A, depois uma da zona B, e assim por diante. Pastas vizinhas na lista são parecidas (mesma zona, municípios contíguos), e o que o sorteio realmente deixa ao acaso é o ponto de partida dentro do intervalo de vinte. Um estimador que mede a variância pelas **diferenças entre pastas consecutivas na ordem do sorteio** captura essa estrutura: em vez de comparar cada pasta com a média do estrato inteiro, compara cada pasta com a sua vizinha. Dentro de cada estrato, com as pastas ordenadas pelo número,

$$\widehat{V}_{SD}(\hat{Y}) = \sum_{h=1}^H \left(1 - \frac{1}{20}\right) \frac{n_h}{2(n_h - 1)} \sum_{i=2}^{n_h} (t_{h,i} - t_{h,i-1})^2.$$

É o estimador que o Census Bureau americano usa para amostras sistemáticas (o “v2” de Wolter) e que o próprio IBGE recomenda para a PNAD. A figura:

ordem no cadastro (pastas urbanas de São Paulo, sorteadas):

pasta	60118	60158	60198	60238	60278	60318	...
zona	A	A	A	A	B	B	...
total	t1	t2	t3	t4	t5	t6	...

conglomerado último: $(t1 - \bar{t})^2 + (t2 - \bar{t})^2 + \dots$ compara cada pasta com a média do estrato

diferenças sucessivas: $(t2 - t1)^2 + (t3 - t2)^2 + \dots$ compara cada pasta com a vizinha

O exemplo. Rendimento alto: 81 vira 69 (−15%); analfabetos: 212 vira 205 (−3%); solteiros: 140 vira 134; construção: 27 vira 25; o urbano do Nordeste sobe de 185 para 189, porque as pastas urbanas do Nordeste não têm padrão espacial que a ordem aproveite. O ganho é maior justamente nas variáveis com forte padrão espacial, que é onde a ordenação por zona e município mais ajuda.

O que exige e o que arrisca. Exige a ordem do sorteio, que as tabelas trazem (pasta e UF; a seção 6.3 demonstra que ela é a do cadastro). Arrisca duas coisas: se a ordem usada não for a do sorteio, o estimador perde a justificativa; e se houver periodicidade no cadastro alinhada com o intervalo de vinte, subestima. A ordem por zona, município e setor não mostra periodicidade.

Como se faz no R. O pacote survey sozinho não constrói pesos de diferenças sucessivas; ele os *consome*, via `svrepdesign(type = "successive-difference")`. Quem os constrói a partir de um desenho é o pacote `svrep`, com `as_sdr_design()`. A receita, com as colunas destas tabelas:

```
library(survey); library(svrep)

# 1. a ordem do sorteio: o número da pasta dentro da UF é a ordem do cadastro (seção 6)
pessoas$ordem_cadastro <- as.integer(pessoas$pasta)
pessoas$fpc <- 1 / 20
pessoas <- pessoas[order(pessoas$censobr_estrato, pessoas$ordem_cadastro), ]

# 2. o desenho como de costume
desenho <- svydesign(ids = ~censobr_upa, strata = ~censobr_estrato,
  weights = ~censobr_weight, fpc = ~fpc, data = pessoas)

# 3. os pesos de diferenças sucessivas (o número de réplicas deve ser múltiplo de 4)
sdr <- as_sdr_design(desenho, replicates = 96, sort_variable = "ordem_cadastro",
  use_normal_hadamard = TRUE)

svytotal(~I(V223B == 351), subset(sdr, !(V202 %in% c(3, 4))), na.rm = TRUE)
```

Dois cuidados. `as_sdr_design()` exige que os dados estejam **ordenados na ordem do sorteio** antes de construir o desenho, e ordena por estrato e depois pela variável indicada; é por isso que a ordenação vem antes. E o método pressupõe que essa ordem seja de fato a do cadastro — o que a seção 6.3 demonstra para esta amostra, mas que deixaria de valer se alguém reordenasse as tabelas.

Quanto custa. Nada, se for pela fórmula: o estimador de conglomerado último e o de diferenças sucessivas levam **menos de um décimo de segundo cada um** neste arquivo — os dois operam sobre os 815 totais por pasta, não sobre as 897 mil linhas, e a única diferença entre eles é uma ordenação. O que custa é a outra forma de calcular a mesma coisa: construir os **pesos replicados** de diferenças sucessivas (`as_sdr_design` com 96 réplicas) leva cerca de dez segundos e produz 96 colunas de peso. Os pesos replicados só compensam se o usuário for calcular muitas estatísticas não lineares.

Cuidado: o svrep não devolve a fórmula acima. Medido em 18/09/2026, na Guanabara: a fórmula de Wolter dá um erro-padrão de 149.043 para a população presente e `as_sdr_design()` dá **157.972**, 6% a mais, e o número não se move com 96, 192, 384 ou 768 réplicas — não é ruído de replicação. O que o pacote implementa é o SDR de **Fay e Train**, que trata a lista como circular: ele soma também $(t_1 - t_n)^2$, a diferença entre a primeira pasta do cadastro e a última, e dispensa o fator $n/(n - 1)$. Escrita em fórmula fechada,

$$\widehat{V}_{\text{SDR}}(\hat{Y}) = \sum_{h=1}^H \left(1 - \frac{1}{20}\right) \frac{1}{2} \left[\sum_{i=2}^{n_h} (t_{h,i} - t_{h,i-1})^2 + (t_{h,1} - t_{h,n_h})^2 \right],$$

ela reproduz o `svrep` no dígito. Na Guanabara o termo circular vale 15,3% da soma das diferenças. As duas variantes são legítimas, mas a de Wolter é a preferível aqui: a primeira e a última pasta do cadastro de uma unidade da federação não são vizinhas em coisa nenhuma, e a diferença entre elas é a de um par qualquer — contá-la infla a variância sem

justificativa de desenho. O fechamento circular é artefato da construção de Hadamard, não hipótese sobre o sorteio. As duas estão implementadas, lado a lado, em `references/estimador_diferencas_sucessivas_1960.R`.

Há ainda uma armadilha do outro lado: num domínio que cabe **numa pasta só**, as diferenças sucessivas não ajudam e chegam a atrapalhar. Com o domínio concentrado na pasta i , as duas diferenças que a envolvem valem t_i^2 cada uma, e o estimador devolve praticamente o mesmo que o de conglomerado último — na Guanabara, 98,7% de coeficiente de variação contra 97,5%. Nenhum estimador de variância conserta um domínio com um conglomerado só (seção 13.8).

Por que é opção, e não padrão. O estimador de conglomerado último é o que qualquer usuário do survey obtém das colunas de desenho sem saber nada sobre a ordem do cadastro; o de diferenças sucessivas dá erros menores, mas depende de uma hipótese a mais (a ordem) e de o usuário preservá-la. Fica documentado como a alternativa mais bem fundamentada para variáveis com padrão espacial.

1.16.5 13.5 A variância depois da calibração: quando ela vale e quando não

Esta subseção tem duas partes. A primeira explica, com `censobr_weight_1965`, por que a variância pós-calibração é uma armadilha quando os totais de calibração vêm da própria amostra; a segunda diz o que muda com `censobr_weight`, cujos totais são externos.

A aritmética. Os pesos de 1965 foram calibrados para que 184 totais sejam reproduzidos exatamente. A teoria de Deville e Särndal diz que o estimador calibrado se comporta como um estimador de regressão, e que a sua variância é a do **resíduo** da regressão ponderada da variável nas colunas de calibração, e não a da variável em si:

$$e_k = y_k - \mathbf{x}_k^\top \hat{\mathbf{B}}, \quad \hat{\mathbf{B}} = \left(\sum_{k \in s} w_k \mathbf{x}_k \mathbf{x}_k^\top \right)^{-1} \sum_{k \in s} w_k \mathbf{x}_k y_k,$$

e $\hat{V}_{\text{cal}}(\hat{Y})$ é o estimador da seção 12.2 aplicado a $w_k e_k$ em vez de $w_k y_k$. Calculada assim, a variância cai muito, e para os próprios totais calibrados cai a zero:

total	erro-padrão adotado	pelos resíduos da calibração de 1965
população urbana do Nordeste	171 mil	0
analfabetos de 15 anos e mais	205 mil	33 mil
solteiros de 15 anos e mais	136 mil	47 mil
rendimento acima de Cr\$ 10 mil	78 mil	61 mil
operários da construção civil	27 mil	24 mil

Por que o zero é um sinal de alarme, e não um resultado. A fórmula está certa; a hipótese é que não vale aqui. Ela supõe que os totais de calibração são **constantes conhecidas**, sem erro — é o caso normal, em que se calibra a um registro administrativo ou a um censo completo. Aqui não é o caso: os totais de 1965 **foram calculados com esta mesma amostra**. O IBGE pegou as 814 pastas, expandiu-as pelo peso de desenho e publicou o resultado. Calibrar a eles não traz nenhuma informação nova sobre o Brasil de 1960; traz de volta os pesos que o IBGE usou, e repara o dano que o arquivo sofreu depois.

Escrito em uma linha: seja S a amostra íntegra de 814 pastas, A o nosso arquivo danificado, e Y a população verdadeira. A calibração faz $\hat{Y}(A) = \hat{Y}(S)$ para as margens. O erro que interessa ao usuário se decompõe em

$$\hat{Y}(A) - Y = \underbrace{[\hat{Y}(A) - \hat{Y}(S)]}_{\text{erro do dano}} + \underbrace{[\hat{Y}(S) - Y]}_{\text{erro amostral de } S}.$$

O primeiro termo é o erro do dano, e é dele que a variância pós-calibração trata. O segundo é o erro amostral da amostra de 1,27%, e **nenhuma calibração a ela mesma o elimina** — é o termo dominante, o que tem efeito de desenho de 3

a 245. Para uma margem, o primeiro termo é zero por construção, e a fórmula devolve zero; mas o segundo continua valendo 171 mil pessoas no caso do urbano do Nordeste.

Portanto, para censobr_weight_1965. O estimador certo é o de conglomerado último aplicado aos pesos calibrados, que é o que a seção 12 descreve e o que o passo 11 calcula. Ele estima a ordem de grandeza certa de $\hat{Y}(S) - Y$. A variância pós-calibração responde a outra pergunta, legítima mas diferente: “quanto o dano do arquivo afastou este número do que a amostra íntegra teria dado?” — útil para avaliar a reparação, não para publicar um intervalo de confiança sobre o Brasil de 1960.

Com censobr_weight, a conta muda de natureza, e o passo 11 a calcula. Os totais do peso final são externos — a contagem completa em onze unidades da federação e a amostra de 25% nas outras dezessete, cuja variância é vinte vezes menor que a desta subamostra e para efeito prático a torna constante. Calibrar a eles reduz a variância de verdade, e aí a fórmula dos resíduos é a correta. Desde 2026-09-15 o passo 11 a calcula com as 543 células do peso final e a grava em erro_padrao_calibrado e cv_calibrado_pct; para censobr_weight_1965 as duas colunas ficam vazias, pela razão acima.

O que ela dá (seção 12.4): zero nas células que foram restrição, legitimamente; 5.618 no total do país, que é o Distrito Federal sozinho; 42 mil no urbano e no rural do Leste, que é o corte urbano/rural das unidades da federação que não tinham oito pastas; e, nas 176 células do quadro 1, uma mediana de 1,3% de coeficiente de variação contra 3,5% do estimador de desenho — 35% do erro-padrão. Nos cinco totais-exemplo (figura 10) a redução vai de 11% nos operários da construção civil a 84% nos analfabetos de 15 anos e mais, e é maior exatamente onde se espera: quanto mais a variável se explica por sexo, idade, situação e alfabetização dentro da unidade da federação, mais dela a calibração já prendeu.

Qual dos dois publicar. Os dois, que é o que o CSV faz, porque respondem a perguntas diferentes. O de desenho responde “quanto esta amostra erraria se eu não soubesse nada sobre os pesos”; é o número conservador, o que um usuário do survey obtém sem esforço, e o único comparável com censobr_weight_1965. O dos resíduos responde “quanto ainda pode errar, dado que 543 totais publicados pelo IBGE estão presos”; é o número certo para quem usa o peso final como ele é, e o único que reconhece a informação externa que entrou. Para as margens da calibração, o segundo é zero — e isso, aqui, não é uma armadilha: é o que significa ter calibrado a um total que o IBGE apurou com a contagem completa ou com uma amostra vinte vezes maior.

1.16.6 13.6 Pesos replicados: jackknife (não será feito)

Decisão. As tabelas não trazem, nem trarão, colunas de pesos replicados de nenhum tipo. As duas subseções seguintes explicam o que eles são, para que o leitor saiba o que está deixando de lado e como obtê-los por conta própria a partir das colunas de desenho, com uma linha do survey.

A ideia. Em vez de fórmula, repetição. Constrói-se uma coleção de conjuntos de pesos, cada um simulando “a amostra sem uma pasta”: retira-se a pasta i do estrato h e multiplicam-se os pesos das outras $n_h - 1$ pastas do estrato por $n_h/(n_h - 1)$, para que o estrato continue somando o mesmo. Calcula-se a estimativa $\hat{Y}_{(hi)}$ com cada conjunto; a dispersão das 815 estimativas em torno da estimativa completa é a variância:

$$\widehat{V}_{JK}(\hat{Y}) = \sum_{h=1}^H \frac{n_h - 1}{n_h} \sum_{i=1}^{n_h} (\hat{Y}_{(hi)} - \hat{Y})^2.$$

Para um total, isto não é um estimador novo. Substituindo $\hat{Y}_{(hi)} - \hat{Y} = n_h(\bar{t}_h - t_{hi})/(n_h - 1)$ na soma, os fatores se cancelam e sobra

$$\widehat{V}_{JK}(\hat{Y}) = \sum_{h=1}^H \frac{n_h}{n_h - 1} \sum_{i=1}^{n_h} (t_{hi} - \bar{t}_h)^2,$$

que é exatamente o estimador de conglomerado último da seção 12.2, sem a correção de população finita — e com ela, se as réplicas a incorporarem. O jackknife só diz algo diferente em estatísticas **não lineares** (razões, quantis, coeficientes de regressão), onde a linearização e a repetição deixam de coincidir. É por isso que ele não tem coluna na tabela comparativa da abertura desta seção.

pasta	peso original	réplica 1 (sem a pasta 1)	réplica 2 (sem a pasta 2) ...
1 (h=A)	78,8	0	78,8 · 3/2
2 (h=A)	78,8	78,8 · 3/2	0
3 (h=A)	78,8	78,8 · 3/2	78,8 · 3/2
4 (h=B)	80,1	80,1	80,1
...			

O exemplo. Para totais e médias o jackknife dá **exatamente** o estimador de conglomerado último sem a correção finita (é uma identidade algébrica): 27, 80, 210, 140 e 175 mil, os mesmos números da coluna “sem correção finita”. Não é ganho de precisão; é ganho de conveniência: o usuário não precisa saber o que é estrato nem pasta, só multiplicar pelas colunas de peso.

O que custa. 815 colunas a mais em 897 mil linhas (uns 6 GB em ponto flutuante), inviável para distribuir. As alternativas de tamanho razoável são o jackknife por grupos aleatórios de pastas (por exemplo, 100 réplicas) ou o bootstrap da subseção seguinte. Com o `survey`, as `svrepdesign(desenho, type = "JK1")` constrói as réplicas a partir de `censobr_upa` e `censobr_estrato` sem gravar nada.

1.16.7 13.7 Pesos replicados: bootstrap de Rao e Wu (não será feito)

A ideia. Em cada estrato, sorteiam-se $n_h - 1$ pastas com reposição entre as n_h sorteadas; se a pasta i saiu $m_{hi}^{(b)}$ vezes na réplica b , os seus pesos são multiplicados por

$$\frac{n_h}{n_h - 1} m_{hi}^{(b)}.$$

Repete-se, digamos, 200 vezes; a variância é a dispersão das 200 estimativas. Diferente do jackknife, o bootstrap funciona também para estatísticas não lineares — medianas, quantis, índice de Gini, coeficientes de modelos —, que são o que muita gente quer estimar com esta amostra.

O que custa. 200 colunas de peso (cerca de 1,4 GB). Quem precisar deles os gera a partir das colunas de desenho: `as.svrepdesign(desenho, type = "subbootstrap", replicates = 200)`.

1.16.8 13.8 Domínios pequenos e o que não fazer

A estimativa de um domínio usa as pastas que têm alguém do domínio, mas a variância usa todas as pastas do estrato (as sem ninguém entram com zero), e é assim que deve ser: um município com uma pasta sorteada é, para fins de variância, um domínio que poderia ter recebido outra pasta e não recebeu nenhuma. Duas regras práticas:

- Um domínio precisa de pastas em pelo menos dois estratos ou de várias pastas num estrato para ter erro-padrão calculável; com uma pasta o erro é indefinido, e com duas é uma estimativa com um grau de liberdade.
- Estimativas por município a partir desta amostra não devem ser publicadas. A amostra foi desenhada para regiões e situações; para municípios ela é uma ou duas pastas de um bairro. O caminho para estimativas locais é a amostra de 25%, que tem dezenas de pastas por município médio, ou modelos de pequenas áreas, que estão fora do escopo deste pipeline.

1.16.9 13.9 O que muda com a amostra de 25%

A amostra de 25% sobreviveu para 17 unidades da federação, com a mesma chave de questionário (distrito, pasta, boletim). O seu desenho é outro e mais simples: um domicílio em quatro, sistematicamente, dentro de cada setor — quase uma amostra aleatória simples estratificada por setor, com efeito de desenho perto de 1. Na compilação, as duas amostras se combinam: onde a de 25% existe, ela domina; onde não existe, a de 1,27% é tudo o que há. Três consequências para o desenho:

- O Distrito Federal volta a ter os seus boletins: a truncagem das duas pastas deixa de importar.
- Nas 17 unidades da federação, os erros-padrão caem para uma fração dos daqui, e a estratificação passa a ser por setor.
- A amostra de 1,27% continua sendo a única nacional, e a única em que se pode reproduzir 1965. Para estimativas nacionais consistentes com as publicadas, ela é a referência; para estimativas estaduais e locais, a de 25%.

1.16.10 13.10 O que está adotado, o que é opção, o que foi descartado e o que é tarefa

Adotado (o que o passo 11 calcula e o que as colunas de desenho dão a qualquer usuário do survey):

1. **Estimador de conglomerado último com correção de população finita** (12.2, 13.2), sobre os 75 estratos de unidade da federação $\times$ situação (11, 13.3), com a unidade solitária juntada a uma vizinha e Fernando de Noronha como estrato de certeza. Confere com o survey até o último dígito, e responde à pergunta que interessa: quanto erra esta amostra em relação ao Brasil de 1960.
2. **A parte que falta da variância da etapa dos domicílios** (12.2, 13.2), somada ao estimador entre pastas. Acrescenta de 0,04% a 0,6% ao erro-padrão; entra porque fecha a conta.
3. **Variância pelos resíduos da calibração para censobr_weight** (12.4, 13.5), nas colunas `erro_padrao_calibrado` e `cv_calibrado_pct`, ao lado da de desenho. É legítima porque os 543 totais do peso final são externos.
4. **Peso final calibrado aos resultados definitivos por unidade da federação** (10.3), com o peso de 1965 ao lado (10.4) para reproduzir a publicação preliminar e medir a distância entre as duas.
5. **Sem variância pós-calibração** para `censobr_weight_1965` (13.5), cujos totais saíram desta mesma amostra: as duas colunas ficam vazias.
6. **A pasta como unidade primária e o domicílio como segunda etapa** (11): a variância vem da dispersão entre pastas, que já contém 95% da variância da etapa dos domicílios, mais o termo acima pelos 5% restantes. Na tabela publicada esse par é escrito explicitamente, em `censobr_upa/censobr_fpc` e `censobr_usa/censobr_fpc2`, para que uma chamada só de `svydesign` devolva a mesma conta.

Opção documentada, não padrão:

7. **Diferenças sucessivas** (13.4), para variáveis com padrão espacial. As tabelas trazem tudo o que ela exige (`censobr_estrato`, `censobr_upa` e a ordem do cadastro em pasta); a fórmula é instantânea.

Descartado:

8. **Pesos replicados** de qualquer tipo (13.6, 13.7). As colunas de desenho bastam para quem quiser construí-los.
9. **Cor como restrição da calibração e margens de idade para as unidades pequenas** (10.3): testadas, produziam fatores de 6 a 7.
10. **Colapso no grupo de situação da região** (13.3), a regra anterior: mais grossa que o desenho e, nos domínios regionais, idêntica à estratificação por região $\times$ situação.

Tarefa: nenhuma pendente no cálculo do erro amostral desta amostra. O que falta depende da amostra de 25% (13.9): a fração de sorteio exata por estrato, o Distrito Federal inteiro e a decisão sobre as 150 famílias sem registro.

1.16.11 13.11 O que deste desenho chega à tabela publicada

Este documento descreve um **estágio**, e o que o `censobr` distribui é a compilação das duas amostras de 1960. Convém dizer, sem repetir o que `microdata_1960_compilacao.md` já explica, o que sobrevive daqui e o que não.

Onze das vinte e oito unidades da federação. Nas dezessete em que a amostra de 25% existe, ela domina: é vinte vezes maior e a de 1,27% é subamostra dela, de modo que empilhar as duas contaria a mesma gente duas vezes. A compilação é uma partição por unidade da federação, e as onze que vêm daqui — Rondônia, Acre, Amazonas, Roraima, Pará, Amapá, Maranhão, Piauí, Espírito Santo, Guanabara e Santa Catarina — são exatamente aquelas cujos tomos do

Volume I foram apurados pelo Boletim Geral completo. A coluna `censobr_amostra` diz, registro a registro, de qual metade ele vem.

Os 75 estratos não sobrevivem ao corte. Eles foram construídos sobre as 28 unidades; sobre as onze que ficam, a regra de colapso foi reexecutada, e o resultado são **21 estratos em 145 pastas**, o menor com duas. A Guanabara é o caso que obrigou a estender a regra: as suas vizinhas de região vêm todas da amostra de 25%, e o grupo solitário teve de se juntar ao maior grupo dela mesma.

O desenho vira de duas etapas, escritas. A pasta continua sendo a unidade primária — `censobr_upa`, com `censobr_fpc = 1/20` —, e o domicílio entra como segunda etapa em `censobr_usa`, com `censobr_fpc2 = 1/4`. Do lado das dezessete a primeira etapa é o próprio domicílio, com fração 1/4, e a segunda é degenerada. Como nenhum estrato e nenhuma unidade primária mistura as duas metades, uma chamada só de `svydesign` descreve o país (seção 14.1).

Os dois registros de chave danificada descem corrigidos. `censobr_upa` na tabela publicada é a pasta do desenho, não a do cartão: `v001` continua com o que o cartão gravou e `censobr_diagnostico` marca os dois. A Guanabara passa de 41 para 40 pastas, e o efeito não é local — o erro-padrão da população presente do **país inteiro** cai de 291.693 para **280.574**, quase 4%, porque uma unidade primária com um domicílio só num estrato de quarenta pesa na soma de quadrados muito além do seu tamanho.

Os pesos foram refeitos nas duas metades, para ficarem na mesma régua: os dois estágios calibram aos resultados definitivos da Série Nacional por unidade da federação. O `censobr_weight` que este documento descreve é, nas onze unidades, o mesmo que a tabela publicada traz.

1.17 14. Como usar em R

Há duas tabelas em jogo e elas pedem chamadas diferentes: a que o `censobr` publica, que é a compilação das duas amostras de 1960, e a deste estágio, que é a subamostra de 1,27% sozinha. Quem vai analisar o censo quer a primeira; quem vai auditar o que está escrito aqui quer a segunda.

1.17.1 14.1 Na tabela publicada

O desenho ali é de duas etapas e está inteiro nas colunas — não é preciso construir nada:

```
library(arrow); library(survey)
options(survey.lonely.psu = "adjust")

pop <- read_parquet("data/microdata_sample/1960/1960_population_v1.0.0.parquet")
pop <- pop[order(pop$censobr_estrato, pop$censobr_upa), ]

des <- svydesign(ids      = ~censobr_upa + censobr_usa,
                strata   = ~censobr_estrato,
                weights  = ~censobr_weight,
                fpc      = ~censobr_fpc + censobr_fpc2,
                data     = pop,
                check.strata = FALSE)
```

O `check.strata = FALSE` não é opcional. Sem ele o `survey` aborta com `attempt to make a table with >= 2^31 elements`: para conferir que nenhuma unidade primária cai em dois estratos, ele monta uma tabela de contingência densa de 3.066.510 pastas por 18.421 estratos, e `table()` do R para em 2^{31} . A checagem é dispensável porque o aninhamento é garantido por construção — nas dezessete unidades da amostra de 25% a unidade primária é o domicílio, que está numa pasta e numa situação só; nas onze é a própria pasta, e o grupo de situação é atributo dela. Medido: nenhuma das 3.066.510 unidades aparece em mais de um estrato. `nest = TRUE` também faz o erro sumir,

porque `check.strata` tem `!nest` por padrão, mas pelo motivo errado — ele renomeia as unidades primárias dentro de cada estrato, um `paste()` sobre 15,1 milhões de linhas, e `censobr_upa` já é único no país.

O custo, medido em 2026-09-21 sobre as 15.145.810 linhas: **136 s** para montar o desenho e **166 s** por `svytotal`, com o objeto ocupando **11,3 GB** — porque o `survey` guarda a tabela inteira dentro dele. Lendo só as colunas de que a conta precisa (`col_select` no `read_parquet`, com as cinco de desenho, o peso e as variáveis a estimar), o mesmo desenho cai para **4,8 GB**. Vale montar uma vez e reaproveitar.

Conferido de ponta a ponta: esse bloco devolve 70.191.146 presentes com erro-padrão 280.575, que é o valor de `data_raw/microdata/1960/compilada/erros_amostrais.csv`. Para um recorte que caiba em memória — uma unidade da federação, uma região —, as diferenças sucessivas da seção 13.4 são viáveis e dão erros-padrão menores; no país inteiro não são, porque 96 colunas de peso replicado sobre 15,1 milhões de linhas passam de 11 GB.

1.17.2 14.2 Nas tabelas deste estágio

Aqui o desenho é de uma etapa só — a pasta —, e a parcela da etapa dos domicílios entra pela conta do passo 11, não pelo `survey`:

```
library(arrow); library(survey)
options(survey.lonely.psu = "adjust")      # só Noronha tem pasta sozinha, mas subconjuntos podem ter

pessoas <- read_parquet("data_raw/microdata/1960/amostra_127/pessoas_1960_amostra_127.parquet")
pessoas$fpc <- ifelse(pessoas$UF == 24, 1, 1 / 20)  # uma pasta em vinte; em Noronha a pasta era o cad

desenho <- svydesign(ids = ~censobr_upa, strata = ~censobr_estrato,
                    weights = ~censobr_weight, fpc = ~fpc, data = pessoas)

# um total com erro-padrão: pessoas presentes por estrato
presentes <- subset(desenho, !(V202 %in% c(3, 4)))
svyby(~I(rep(1, nrow(presentes))), ~censobr_estrato, presentes, svytotal)

# uma proporção: sabem ler entre os presentes de 5 anos e mais
alf <- subset(presentes, V204 == 1 & V204B >= 5 | V204 == 5)
svymean(~I(V211 %in% c(0, 1)), alf, na.rm = TRUE)

# uma média com domínio: idade média dos operários da construção civil, com o efeito de desenho
svymean(~V204B, subset(presentes, V223B == 351 & V204 == 1), deff = TRUE)
```

1.17.3 14.3 Quatro cuidados, nas duas

Recorte o desenho, não a tabela. Subconjuntos devem sair de `subset()` sobre o objeto de desenho, nunca de um filtro aplicado aos dados antes de construí-lo, para que as pastas sem ninguém do domínio continuem contadas com total zero. Filtrar antes subestima a variância.

Domicílios usam as mesmas colunas e os mesmos pesos, uma linha por domicílio. Famílias, não: o peso é por domicílio (seção 2.1).

Não estime abaixo do município. Uma estimativa municipal é, em geral, a de uma ou duas pastas; não tem erro-padrão calculável e não deve ser publicada como estimativa municipal. Pior ainda por distrito ou bairro: num domínio que cabe numa pasta só, o coeficiente de variação de um total fica perto de 100% por construção, e uma proporção interna àquela pasta sai com erro-padrão **zero**, que é falsa precisão e não precisão (seção 13.8).

O que o `survey` devolve é o erro-padrão de desenho. Para o que a calibração já prendeu, use a coluna `erro_padrao_calibrado` do CSV do passo 11, ou refaça a conta com `survey::calibrate()` sobre as mesmas 543 células — o script da conferência mostra como.

1.18 15. Limitações e cuidados

- **O desenho é reconstruído.** O critério geográfico, a regra da cidade grande e a classificação de cada pasta são a leitura do Volume II verificada contra o cadastro (Parte II). Onde a verificação não é possível (as 11 unidades da federação sem amostra de 25%) ou onde a classificação de uma pasta pode diferir da do IBGE, o erro do estimador é para o lado conservador.
- **O Distrito Federal está truncado** e o que falta não é aleatório: a construção civil é o único ramo que não fecha ali, e a amostra de 25% mostra que 59% dos boletins do DF eram de morador de domicílio coletivo (seção 4). Com `censobr_weight` ele fica no peso de desenho, em 31% da população publicada; com `censobr_weight_1965` ele soma ao Norte e Centro-Oeste o que o arquivo perdeu. A compilação com a amostra de 25% resolve, porque lá o DF está inteiro.
- **Cobertura parcial** de Rondônia, Amapá, Acre, Roraima, Fernando de Noronha e Distrito Federal: poucas pastas, e em alguns casos uma situação só.
- **Domínios pequenos.** Com efeitos de desenho de 4 a 10, uma célula precisa de milhares de pessoas na amostra para ter erro relativo abaixo de 5%.
- **Comparações com 1965.** Os quadros 1 e 2 são reproduzidos exatamente por construção; os demais diferem por poucos por cento, e as diferenças estão explicadas ou documentadas no documento de preparação (seção 7).

1.19 16. Glossário

- **Amostra de 25%:** a amostra geral do Censo de 1960, um domicílio em quatro, com o Boletim de Amostra.
- **Amostra de 1,27%:** subamostra de uma pasta em vinte da amostra de 25%, com que o IBGE publicou os resultados preliminares de 1965. É este arquivo.
- **Boletim de Amostra (CD 2):** o questionário longo, de um domicílio, aplicado à amostra de 25%.
- **Cadastro:** a lista de todas as pastas de uma unidade da federação, de onde as sorteadas foram tiradas; reconstruído a partir da amostra de 25%.
- **Calibração:** ajuste dos pesos para que a amostra reproduza totais conhecidos; aqui, as margens demográficas de 1965.
- **Coefficiente de variação (CV):** erro-padrão dividido pela estimativa.
- **Conglomerado:** um grupo de unidades sorteado em bloco; aqui, a pasta.
- **Correção de população finita:** o fator $(1 - f)$ que desconta da variância a fração f do cadastro que a amostra tomou; aqui, $1 - 1/20$.
- **Efeito de desenho (deff):** variância do desenho real dividida pela de uma amostra aleatória simples do mesmo tamanho.
- **Estrato:** grupo dentro do qual o sorteio foi feito separadamente; aqui, unidade da federação $\times$ grupo de situação da pasta.
- **Folha de Coleta (CD 7, CD 8):** a lista dos domicílios de um setor; as suas “linhas de amostra” a cada quatro linhas sortearam a amostra de 25%.
- **Pasta:** lote de trabalho de cerca de 250 boletins de amostra, na ordem dos setores; a unidade sorteadas.
- **Peso de desenho:** inverso da fração de amostragem, 78,74.
- **Peso integrado:** um peso por domicílio, igual para todas as suas pessoas.
- **Raking:** a forma de calibração usada, que multiplica cada peso de desenho por um fator $\exp(\mathbf{x}^\top \lambda)$.
- **Situação:** urbana, suburbana ou rural, do domicílio ou da pasta.
- **Unidade primária de amostragem (UPA):** a unidade sorteadas na etapa que interessa à variância; aqui, a pasta.
- **Zona fisiográfica:** divisão regional do IBGE dentro de cada estado, que ordena o cadastro.

1.20 17. Fontes

- IBGE, Serviço Nacional de Recenseamento. *Censo Demográfico: resultados preliminares*. Série Especial, vol. II. Rio de Janeiro, março de 1965 (Biblioteca do IBGE, liv84480; cópia em `references/fontes_1960/1965_resultados`, pp. 10–11 para o desenho; transcrição dos sete quadros em `references/censo_1960_resultados_preliminares_1965.csv`).

- IBGE. *Censo Demográfico de 1960*, Série Regional, Volume I (19 tomos; onze unidades da federação em duas partes, 1967–1969; dezessete em volume único, anos 1970): a seção “Amostragem” da introdução descreve a amostra de 25% (linhas de amostra nas Folhas de Coleta CD 7 e CD 8) e a estimativa de razão em 48 grupos, e promete de novo o volume com os erros de amostragem. Em D:\Dropbox\Bancos_Dados\Censos\Censo 1960\4 - Ponderação do Censo de 1960\3-Publicações Originais dos Resultados\ (as primeiras partes e os volumes únicos) e na Biblioteca do IBGE, biblioteca.ibge.gov.br/visualizacao/periodicos/68/cd_1960 (inclusive as segundas partes).
- IBGE. *Censo Demográfico de 1960 — Brasil*, Série Nacional, Volume I (177 p., 62 tabelas; Fundação IBGE, anos 1970): a “Apresentação” que explica os dois grupos de tomos e a apuração das dezessete unidades da federação só pelo Boletim de Amostra, e as tabelas por unidade da federação a que o peso final é calibrado. Internet Archive, item [censodem1960br](https://archive.org/details/censodem1960br/copia_em_references/fontes_1960/1960_serie_nacional_vol1_brasil.pdf); cópia em [references/fontes_1960/1960_serie_nacional_vol1_brasil.pdf](https://archive.org/details/censodem1960br/copia_em_references/fontes_1960/1960_serie_nacional_vol1_brasil.pdf); tabelas 32, 33, 34, 37, 40 e 7 transcritas por [references/transcricao_1960_serie_nacional.py](https://archive.org/details/censodem1960br/copia_em_references/transcricao_1960_serie_nacional.py) em [references/censo_1960_resultados_definitivos_serie_nacional.csv](https://archive.org/details/censodem1960br/copia_em_references/censo_1960_resultados_definitivos_serie_nacional.csv).
- IPEA. *Processamento de uma amostra do Censo Demográfico de 1960*, abril de 1969: a história dos cartões e o leiaute do cartão de pessoa. Cópia em [references/fontes_1960/1969_ipea_processamento_amostra_1960.pdf](https://archive.org/details/censodem1960br/copia_em_references/fontes_1960/1969_ipea_processamento_amostra_1960.pdf).
- IBGE. *Censo Demográfico de 1960 — Favelas, Estado da Guanabara*. Série Especial, vol. IV: as favelas cariocas por zona e circunscrição censitária, a partir dos resultados **definitivos**, não desta subamostra. Cópia em [references/fontes_1960/1960_serie_especial_vol4_favelas.pdf](https://archive.org/details/censodem1960br/copia_em_references/fontes_1960/1960_serie_especial_vol4_favelas.pdf).
- IBGE, Serviço Nacional de Recenseamento. *Código do Censo Demográfico – 1960* (manual de codificação, 25 p.); *Código para uso da Agência Municipal de Estatística* (236 p.); *Código de Zonas Fisiográficas, Municípios e Distritos, situação em 1º-7-1960* (313 p.). Transcrições em [read_guides/1960_codigo_do_censo.csv](https://archive.org/details/censodem1960br/copia_em_references/read_guides/1960_codigo_do_censo.csv), [read_guides/1960_municipios.csv](https://archive.org/details/censodem1960br/copia_em_references/read_guides/1960_municipios.csv) e [read_guides/1960_distritos.csv](https://archive.org/details/censodem1960br/copia_em_references/read_guides/1960_distritos.csv).
- IBGE. *Anuário Estatístico do Brasil, 1961*: população total, urbana e rural dos municípios em 1960, em [read_guides/1960_municipios.csv](https://archive.org/details/censodem1960br/copia_em_references/read_guides/1960_municipios.csv).
- A amostra de 25% do Censo de 1960, na compilação que o censobr distribui ([release_legacy](https://archive.org/details/censodem1960br/copia_em_references/release_legacy)): o cadastro de pastas que permitiu demonstrar os estratos (Parte II).
- Deville, J.-C. e Särndal, C.-E. (1992). Calibration estimators in survey sampling. *Journal of the American Statistical Association*, 87, 376–382.
- Wolter, K. M. (2007). *Introduction to Variance Estimation*, 2ª ed. Springer — o estimador de diferenças sucessivas para amostras sistemáticas.
- Rao, J. N. K. e Wu, C. F. J. (1988). Resampling inference with complex survey data. *Journal of the American Statistical Association*, 83, 231–241.
- O pipeline: [R/microdata_1960_amostra_127.R](https://archive.org/details/censodem1960br/copia_em_references/microdata_1960_amostra_127.R), passos 8 (desenho), 9 (calibração) e 11 (erros amostrais); [references/microdata_1960_amostra_127_preparacao.md](https://archive.org/details/censodem1960br/copia_em_references/microdata_1960_amostra_127_preparacao.md), seções 7 e 8.
- A investigação e as figuras: [references/figuras/desenho_amostral_1960.R](https://archive.org/details/censodem1960br/copia_em_references/figuras/desenho_amostral_1960.R) (refaz a Parte II e as figuras 1 a 9) e [references/conferencia_desenho_amostral_1960.R](https://archive.org/details/censodem1960br/copia_em_references/conferencia_desenho_amostral_1960.R) (confere o passo 11 contra o survey e mede o custo dos estimadores).